



Mémoire de Projet de Fin d'Études

Présenté en vue de l'obtention du Master

Spécialité : Big Data et Internet des Objets

*** * CHARMAQE Hamza * ***

Titre :

*Conception d'une solution data-driven pour le suivi et l'analyse
des opérations de merchandising terrain du projet Unilever
chez Smollan Morocco*



Société d'Accueil: *Smollan*

SMOLLAN

Soutenu le : 22/06/2026 devant le jury composé de :

- | | | |
|----------------------|------------------------------------|------------------|
| • xxxxxxxxxxxxxxxx : | Professeur à l'ENSAM de Casablanca | Président |
| • xxxxxxxxxxxxxxxx : | Responsable à la société | Parrain de stage |
| • xxxxxxxxxxxxxxxx : | Professeur à l'ENSAM de Casablanca | Examineur |
| • xxxxxxxxxxxxxxxx : | Professeur à l'ENSAM de Casablanca | Encadrant |

DÉDICACES

Je dédie ce travail à mes chers parents, pour leur soutien, leurs sacrifices et leur confiance tout au long de mon parcours académique. Leur encouragement permanent a constitué une source essentielle de motivation et de persévérance.

Je le dédie également à ma famille, à mes proches et à toutes les personnes qui m'ont accompagné, conseillé ou soutenu durant cette période de formation et de stage.

Enfin, je dédie ce mémoire à l'ensemble des enseignants et encadrants qui ont contribué à ma formation et à mon développement personnel et professionnel.

REMERCIEMENTS

Je tiens tout d'abord à exprimer ma profonde gratitude à l'École Nationale Supérieure d'Arts et Métiers de Casablanca, ainsi qu'à l'ensemble du corps professoral du Master Big Data et Internet des Objets, pour la qualité de la formation dispensée et pour l'accompagnement assuré tout au long de mon parcours académique.

J'adresse mes sincères remerciements à mon encadrant pédagogique, pour son suivi, ses orientations et ses remarques constructives durant la réalisation de ce Projet de Fin d'Études. Ses conseils ont contribué à mieux structurer le travail réalisé et à l'inscrire dans une démarche académique rigoureuse.

Je remercie également Smollan Morocco pour m'avoir accueilli dans le cadre de mon stage de fin d'études et pour m'avoir offert l'opportunité de travailler sur un projet concret, lié à l'exploitation des données terrain et au suivi des opérations de merchandising. Cette expérience m'a permis de mettre en pratique mes compétences en data engineering, analyse de données et conception de solutions orientées données dans un contexte professionnel réel.

Mes remerciements s'adressent aussi à mon encadrant professionnel, ainsi qu'à l'ensemble des collaborateurs de Smollan Morocco avec lesquels j'ai eu l'occasion d'échanger. Leur disponibilité, leurs explications et leur accompagnement ont été essentiels pour comprendre le contexte métier, les données utilisées et les besoins opérationnels liés au projet Unilever.

Enfin, je remercie ma famille et mes proches pour leur soutien, leur patience et leurs encouragements constants. Leur présence a constitué une source importante de motivation tout au long de cette période.

RÉSUMÉ

Résumé — Français

Ce projet porte sur la mise en place d'une plateforme data-driven pour le suivi de l'exécution terrain du merchandising Unilever chez Smollan Morocco. La solution centralise les données Data Dump et Coverage, automatise leur traitement via un pipeline ETL Python, les stocke dans MySQL et propose des interfaces de suivi, d'analyse et de validation opérationnelle.

Mots-clés : Data Engineering, ETL, MySQL, merchandising, validation métier, OSA, back-office.

Abstract — English

This project focuses on building a data-driven platform for monitoring Unilever merchandising field execution at Smollan Morocco. The solution centralizes Data Dump and Coverage data, automates processing through a Python ETL pipeline, stores it in MySQL, and provides monitoring, analysis, and operational validation interfaces.

Keywords: Data Engineering, ETL, MySQL, merchandising, business validation, OSA, back-office.

Résumé — Arabe

Le résumé en arabe sera intégré dans la version finale après validation du format de compilation.

ABSTRACT

Keywords:

TABLE DES MATIERES

Dédicaces	i
Remerciements	ii
Résumé	iii
Abstract	iv
Liste des figures	x
Liste des tableaux	xi
Liste des abreviations	xii
Introduction générale	1
1 Contexte général du projet	3
I. Introduction	3
II. Présentation de l'organisme d'accueil	3
II.1 Présentation générale de Smollan	3
II.2 Domaines d'activité de Smollan	4
II.3 Principaux clients et partenaires de Smollan	5
III. Présentation du client Unilever	5
IV. Contexte métier du merchandising terrain	6
V. Problématique	7
VI. Objectifs du projet	7
VII. Méthodologie de travail	8
VII.1 Démarche adoptée	8
VII.2 Phases du projet	9
VII.3 Planification du projet	9
VIII. Conclusion	10

2	État de l'existant et cadre théorique	11
I.	Introduction	11
II.	Cadre théorique du projet	11
II.1	Merchandising terrain et exécution en point de vente	11
II.2	Indicateurs de suivi opérationnel	11
II.2.1	Taux de couverture	12
II.2.2	Taux de déviation	12
II.2.3	Taux de rejet	13
II.2.4	Disponibilité produit : OSA	13
II.2.5	Visibilité en rayon : SOS	14
II.2.6	Planogramme et placements	14
II.2.7	Taux de complétion des tâches	15
II.3	Exploitation des données terrain	15
III.	Processus actuel de suivi opérationnel	16
IV.	Sources de données exploitées	17
IV.1	Fichier Data Dump	17
IV.2	Fichier Coverage	18
IV.3	Complémentarité Data Dump / Coverage	18
V.	Rapports existants	19
V.1	Rapports internes Smollan	20
V.2	Rapports destinés au client Unilever	20
VI.	Limites du processus actuel	21
VII.	Besoins fonctionnels	22
VIII.	Besoins techniques	23
IX.	Conclusion	23
3	Conception globale de la solution	25
I.	Introduction	25
II.	Vision générale de la solution	25
III.	Architecture globale	26
IV.	Séparation des couches fonctionnelles	27

IV.1	Couche d'acquisition des données	27
IV.2	Couche d'orchestration et de Data Engineering	27
IV.3	Couche centrale de données	27
IV.4	Couche Business Intelligence	28
IV.5	Couche applicative de consultation et de validation	28
V.	Choix technologiques	28
V.1	Outils d'acquisition et d'orchestration	29
V.2	Outils de traitement et de structuration des données	29
V.3	Outils de centralisation et de restitution analytique	30
V.4	Outils de la couche applicative	30
V.5	Synthèse des choix technologiques	31
VI.	Conclusion	31
4	Développement de la solution adoptée	32
I.	Introduction	32
II.	Mise en place du pipeline Data Engineering	32
II.1	Ingestion des fichiers Excel	33
II.1.1	Lancement du pipeline	34
II.1.2	Interface de sélection des fichiers	34
II.1.3	Configuration de l'environnement	35
II.1.4	Orchestration et suivi d'exécution avec Prefect	36
II.2	Traitement du fichier Data Dump	38
II.2.1	Principe général de transformation	38
II.2.2	Étude de cas OSA : transformation en colonnes dynamiques .	39
II.2.3	Étude de cas SOS : transformation en structure verticale . . .	39
II.2.4	Sorties générées et fiabilisation du rechargement	40
II.3	Intégration du Coverage et rapprochement avec le Data Dump	40
II.3.1	Rôle de la table de couverture opérationnelle	41
II.3.2	Rapprochement optionnel avec les visites détaillées	41
II.3.3	Apport dans la solution	43
II.4	Modélisation et chargement dans MySQL	43

II.4.1	Stratégie de chargement	44
II.4.2	Traçabilité des traitements	44
III.	Structuration de la base de données	44
IV.	Mise en place du moteur de validation	46
IV.1	Principe général du moteur de validation	46
IV.2	Règle de validation OSA pour les formats MT	47
IV.3	Règle de validation GPS pour les formats GT	47
IV.4	Stockage des résultats de validation	47
V.	Développement de la couche Business Intelligence	48
V.1	Objectif de la couche BI	48
V.2	Connexion directe à la base MySQL	48
V.3	Sélection des tables utiles	49
V.4	Préparation du modèle Power BI	49
V.5	Mesures et indicateurs construits	50
V.6	Vues de restitution préparées	51
VI.	Développement de la couche backend	51
VI.1	Architecture Spring Boot et Java	51
VI.2	APIs REST destinées à l'application mobile	51
VI.3	APIs REST destinées au back-office	51
VII.	Développement des interfaces applicatives	51
VII.1	Interface mobile Expo / React Native	51
VII.2	Portail back-office React	51
VII.3	Limites actuelles de l'authentification	51
VIII.	Conclusion	51
5	Réalisation, tests et résultats	52
I.	Introduction	53
II.	Résultats du pipeline Data Engineering	53
II.1	Exécution du pipeline ETL	53
II.2	Données chargées dans MySQL	53
II.3	Journaux d'exécution	53

III.	Résultats du moteur de validation	53
III.1	Résultats de la règle OSA pour les formats MT	53
III.2	Résultats de la règle GPS pour les formats GT	53
III.3	Exemples de situations détectées	53
IV.	Tests des services backend	53
IV.1	Tests des APIs mobiles	53
IV.2	Tests des APIs back-office	53
V.	Résultats des tableaux de bord Power BI	53
V.1	Dashboard exécutif	53
V.2	Dashboard Merchandiser Performance Intelligence	53
V.3	Analyse GT / MT	53
V.4	Apport pour le management et le field team	53
VI.	Résultats des interfaces applicatives	53
VI.1	Interface mobile de consultation	53
VI.2	Portail back-office de validation	53
VII.	Limites et état actuel de la solution	53
VIII.	Conclusion	53
Conclusion generale		54
Bibliographie		55
A Annexes		56
I.	Schemas techniques	56
II.	Captures d'écran	56
III.	Exemples techniques	56

LISTE DES FIGURES

1.1	Logo de Smollan.	3
1.2	Principaux domaines d'activité de Smollan.	4
1.3	Illustration de l'écosystème de partenaires et clients de Smollan	5
1.4	Logo d'Unilever	6
1.5	Acteurs et flux métier des opérations de merchandising terrain	7
1.6	Phases principales de réalisation du projet.	9
1.7	Illustration de la planification générale du projet	9
2.1	Processus actuel de reporting merchandising basé sur Smart 3 et les exports Excel	17
3.1	Architecture globale de la solution data-driven	26
4.1	Flux général du pipeline Data Engineering	33
4.2	Commande de lancement du pipeline ETL	34
4.3	Interface de sélection des fichiers du pipeline ETL	34
4.4	Exemple anonymisé de configuration de l'environnement	35
4.5	Démarrage du serveur Prefect	36
4.6	Vue des runs supervisés dans Prefect	37
4.7	Vue globale de l'orchestration du pipeline dans Prefect	37
4.8	Transformation du Data Dump vers les tables SQL : exemples OSA et SOS . .	38
4.9	Implémentation de la vue SQL de rapprochement dans la base <i>unilever_db</i> . . .	42
4.10	Organisation logique des données dans MySQL	43
4.11	Modèle relationnel simplifié de la base <i>unilever_db</i>	45
4.12	Connexion de Power BI à la base MySQL <i>unilever_db</i>	49
4.13	Modèle relationnel préparé dans Power BI	50

LISTE DES TABLEAUX

2.1	Comparaison entre les fichiers Data Dump et Coverage	19
2.2	Synthèse des reportings existants	21
4.1	Étude de cas OSA : transformation en colonnes dynamiques	39
4.2	Étude de cas SOS : transformation en structure verticale	40

LISTE DES ABRÉVIATIONS

API	Application Programming Interface
BI	Business Intelligence
ETL	Extract, Transform, Load
GPS	Global Positioning System
GT	General Trade
KPI	Key Performance Indicator
MT	Modern Trade
PFE	Projet de Fin d'Etudes
SQL	Structured Query Language
UML	Unified Modeling Language
SOS	Share of Shelf

INTRODUCTION GÉNÉRALE

Dans le secteur des biens de grande consommation, la performance commerciale ne dépend pas uniquement de la disponibilité des produits au niveau des entrepôts ou des circuits de distribution. Elle dépend également de la qualité de l'exécution réalisée sur le terrain, au niveau des points de vente. La présence effective des produits en rayon, le respect des standards de merchandising, la qualité du placement, la visibilité des marques et la fiabilité des informations remontées constituent des éléments essentiels pour assurer un suivi opérationnel efficace et soutenir la prise de décision.

Dans ce contexte, les entreprises accordent une importance croissante aux données issues des opérations terrain. Ces données permettent de suivre l'activité des équipes, d'évaluer la couverture des magasins, d'identifier les situations nécessitant une intervention et de produire des indicateurs destinés aux responsables opérationnels ainsi qu'aux clients. Toutefois, lorsque ces informations sont exploitées à travers plusieurs fichiers, rapports et traitements manuels, leur utilisation peut devenir complexe, répétitive et difficile à fiabiliser dans le temps.

Le présent Projet de Fin d'Études s'inscrit dans le cadre d'un stage réalisé au sein de Smollan Morocco, en tant que Data Analyst Intern, autour du projet Unilever. Smollan Morocco assure le suivi de l'exécution terrain des opérations de merchandising pour différents clients, dont Unilever. Dans ce cadre, les merchandisers effectuent leurs visites en magasin à travers l'application mobile Smart 3. Les données collectées sont ensuite synchronisées vers le portail Smollan, à partir duquel des fichiers Excel, notamment les fichiers Data Dump et Coverage, sont exportés et exploités par les équipes opérationnelles.

Ces fichiers constituent une base importante pour la production des rapports de suivi. Ils permettent notamment de préparer des rapports internes liés à la couverture, aux déviations, aux magasins couverts, non visités ou rejetés, ainsi que des rapports destinés au client portant sur des indicateurs tels que l'OSA, le SOS, la qualité, le planogramme ou encore les placements secondaires. Cependant, l'exploitation quotidienne de ces données reste fortement dépendante de fichiers Excel, de traitements séparés et de contrôles manuels. Cette situation limite la centralisation de l'information, rend le suivi historique moins fluide et complique l'identification rapide de certaines anomalies opérationnelles.

Le sujet de ce PFE porte ainsi sur la conception d'une solution data-driven pour le suivi et l'analyse des opérations de merchandising terrain du projet Unilever chez Smollan Morocco. L'objectif n'est pas de remplacer entièrement les outils et rapports existants, mais de proposer une approche complémentaire permettant de structurer les données, d'améliorer leur exploitation et de fournir aux équipes concernées une vision plus claire de l'activité terrain. La solution vise notamment à centraliser les données issues des exports, à automatiser une partie des traitements, à appliquer des règles de validation métier et à restituer les résultats à travers des supports de suivi adaptés aux besoins opérationnels.

La démarche adoptée repose d'abord sur l'analyse de l'existant et la compréhension du processus métier, depuis la visite effectuée par le merchandiser jusqu'à l'exploitation des données par les équipes internes. Ensuite, les principales sources de données ont été étudiées afin de définir un processus de traitement permettant de préparer, organiser et charger les informations dans une base de données relationnelle. Cette base constitue le socle de la solution et permet d'alimenter les différentes composantes mises en place, notamment les règles de validation, les interfaces de consultation et les tableaux de bord de suivi.

Sur le plan méthodologique, la solution s'appuie sur une chaîne de traitement des données, une base relationnelle structurée et des outils de restitution orientés vers le suivi opérationnel. Des règles de validation métier ont également été intégrées afin d'identifier certaines situations nécessitant une revue, telles que des incohérences liées à la disponibilité des produits ou au contrôle des visites. L'ensemble de ces éléments permet de construire une solution progressive, adaptée aux besoins du projet et alignée avec le contexte réel de l'entreprise.

Ce rapport présente les différentes étapes de réalisation du projet. Le premier chapitre décrit le contexte général du stage, l'organisme d'accueil et l'environnement métier du projet. Le deuxième chapitre analyse l'existant, les besoins identifiés et les limites du processus actuel. Les chapitres suivants présentent la solution retenue, son organisation générale, les choix effectués, les principales composantes mises en place, ainsi que les résultats obtenus. Enfin, le rapport se termine par une conclusion générale mettant en évidence les apports du travail réalisé, ses limites et les perspectives d'amélioration possibles.

CHAPITRE 1 : CONTEXTE GÉNÉRAL DU PROJET

I. Introduction

Ce premier chapitre présente le cadre général dans lequel s'inscrit le Projet de Fin d'Études réalisé au sein de Smollan Morocco. Il introduit l'organisme d'accueil, le client concerné par le projet, ainsi que le contexte métier lié aux opérations de merchandising terrain du projet Unilever.

Il permet également de préciser la problématique identifiée, les objectifs poursuivis et la démarche de travail adoptée durant le stage. Cette étape de cadrage est nécessaire afin de situer le projet dans son environnement professionnel avant d'aborder l'analyse de l'existant et la conception de la solution proposée.

II. Présentation de l'organisme d'accueil

II.1 Présentation générale de Smollan

Smollan est un groupe international spécialisé dans les services d'exécution commerciale, de merchandising et d'accompagnement des marques dans l'environnement retail. Son activité consiste à soutenir les entreprises dans l'amélioration de leur présence en point de vente, le suivi de l'exécution terrain et l'exploitation des informations collectées auprès des magasins.

L'intervention de Smollan s'appuie sur une combinaison de présence terrain, de coordination opérationnelle et d'analyse des données. Cette approche permet aux clients de disposer d'une meilleure visibilité sur la disponibilité de leurs produits, la qualité de leur exposition, le respect des standards merchandising et l'évolution des indicateurs de performance au niveau des points de vente.

Dans le cadre du présent stage, le projet a été réalisé au sein de Smollan Morocco, dans un contexte lié au suivi et à la valorisation des données terrain du projet Unilever.



Figure 1.1 Logo de Smollan.

Ce logo permet d'identifier l'organisme d'accueil dans lequel s'inscrit le Projet de Fin d'Études.

II.2 Domaines d'activité de Smollan

Les activités de Smollan s'articulent autour de plusieurs services complémentaires liés à l'exécution commerciale et au suivi des performances en point de vente. Ces services couvrent notamment le merchandising terrain, l'activation commerciale, la collecte d'informations en magasin, le reporting opérationnel et l'analyse des données issues des activités terrain.

Le merchandising constitue l'un des axes importants de ces activités. Il consiste à assurer la bonne présence des produits en magasin, à vérifier leur disponibilité, à contrôler leur visibilité en rayon et à veiller au respect des standards définis par les marques. Ces actions permettent aux clients de suivre la qualité de l'exécution commerciale au niveau des points de vente.

Smollan intervient également dans la collecte et l'exploitation des données opérationnelles. Les informations remontées par les équipes terrain permettent de produire des indicateurs de suivi, d'identifier les écarts d'exécution et d'accompagner les décisions liées au pilotage de l'activité. Cette dimension data prend une place importante dans les projets de suivi, car elle permet de passer d'une simple observation terrain à une analyse plus structurée des opérations.

Dans le cadre du présent Projet de Fin d'Études, l'intérêt porte principalement sur cette articulation entre l'exécution terrain et l'exploitation des données. Le projet Unilever étudié chez Smollan Morocco s'inscrit directement dans cette logique, puisqu'il repose sur la collecte, le traitement et l'analyse des données issues des visites réalisées en magasin.

La figure suivante propose une synthèse des principaux domaines d'activité de Smollan.




Figure 1.2 Principaux domaines d'activité de Smollan.

Cette figure met en évidence la diversité des domaines d'intervention de Smollan. Elle montre également le lien entre les activités terrain, le suivi opérationnel et l'exploitation des données, qui constituent le cadre dans lequel s'inscrit le présent projet.

II.3 Principaux clients et partenaires de Smollan

Smollan accompagne différents types de marques, de distributeurs et de partenaires opérant dans des environnements commerciaux variés. Ces collaborations peuvent concerner les biens de grande consommation, les boissons, l'hygiène et les soins, la technologie, le retail ou encore l'agroalimentaire.

Dans le cadre du présent Projet de Fin d'Études, le périmètre étudié reste toutefois limité aux opérations de merchandising terrain liées au projet Unilever. Cette précision permet de distinguer l'écosystème général de Smollan du champ d'analyse réellement traité dans ce rapport.

La figure suivante illustre l'écosystème général dans lequel s'inscrivent les activités de Smollan.




Figure 1.3 Illustration de l'écosystème de partenaires et clients de Smollan

Cette illustration permet de situer Smollan dans un environnement composé de plusieurs types de clients et partenaires. Elle ne vise pas à présenter l'ensemble des collaborations de l'entreprise, mais à contextualiser le projet avant de se concentrer sur le cas Unilever.

III. Présentation du client Unilever

Unilever est une entreprise internationale opérant dans le secteur des biens de grande consommation. Ses activités couvrent plusieurs catégories de produits, notamment les soins personnels, l'hygiène, l'entretien de la maison, l'alimentation et d'autres produits utilisés quotidiennement par les consommateurs.

Dans le cadre des opérations de merchandising, Unilever accorde une importance particulière à la disponibilité de ses produits en magasin, à leur visibilité en rayon, au respect des standards d'exécution et à la qualité de la présence de ses marques dans les points de vente. Ces éléments sont essentiels pour soutenir la performance commerciale et assurer une meilleure expérience d'achat.

Dans le cadre de ce PFE, Unilever constitue le client autour duquel s'articule le périmètre

d'analyse. Le travail porte plus précisément sur les données issues des opérations de merchandising terrain, avec pour objectif de faciliter le suivi, l'analyse et la consultation des informations d'exécution.

La figure suivante présente le logo du client concerné par le projet.



Figure 1.4 Logo d'Unilever

La présence du logo permet d'identifier le client autour duquel s'articulent les opérations de merchandising étudiées dans ce projet.

IV. Contexte métier du merchandising terrain

Le merchandising terrain regroupe l'ensemble des actions réalisées en point de vente afin d'assurer la disponibilité, la visibilité et la bonne présentation des produits. Dans le cadre du projet Unilever, ces actions sont réalisées par des merchandisers qui effectuent des visites en magasin à l'aide de l'application Smart 3.

Lors de chaque visite, le merchandiser renseigne plusieurs informations relatives à l'exécution terrain. Ces informations peuvent concerner la disponibilité des produits, la qualité d'exécution, le respect du planogramme, le placement primaire ou secondaire, le SOS (Share of Shelf), les relevés de prix, les photos justificatives, ainsi que les données de localisation collectées par l'application.

Le suivi de ces opérations repose sur une chaîne d'information allant de la collecte terrain jusqu'à l'exploitation des données par les équipes concernées. Les informations saisies permettent d'assurer un suivi opérationnel interne, notamment pour vérifier l'avancement des visites, les écarts de couverture, les magasins non visités ou les situations nécessitant une justification. Elles servent également à préparer des reportings destinés au client, principalement autour de la disponibilité produit, de la qualité d'exécution, de la visibilité en rayon et des indicateurs de merchandising.

Dans ce contexte, la donnée terrain constitue un élément central du pilotage opérationnel. Elle ne permet pas seulement de constater qu'une visite a été réalisée, mais aussi d'analyser la qualité de l'exécution, de suivre les performances des opérations et d'orienter les actions de correction lorsque certaines situations nécessitent une revue.

La figure suivante présente une vue simplifiée des principaux acteurs et flux métier liés aux opérations de merchandising terrain.



Figure 1.5 Acteurs et flux métier des opérations de merchandising terrain

Ce schéma montre que les informations collectées en magasin constituent la base du suivi opérationnel. Elles sont saisies dans l'application Smart 3, synchronisées vers le portail Smollan, puis exploitées pour alimenter le suivi interne et les reportings destinés au client Unilever.

V. Problématique

Le suivi des opérations terrain du projet Unilever repose sur des données collectées quotidiennement à travers l'application Smart 3, puis exportées depuis le portail Smollan sous forme de fichiers Excel. Ces fichiers contiennent une quantité importante d'informations relatives aux visites, aux magasins, aux merchandisers, aux produits et aux tâches exécutées.

Cependant, l'exploitation de ces données devient moins fluide lorsque les informations sont réparties entre plusieurs fichiers et reportings. Le fichier Data Dump apporte le détail des réponses terrain, tandis que le fichier Coverage permet de suivre les visites planifiées, réalisées, rejetées, déviées ou non effectuées. Cette séparation nécessite un travail de rapprochement et de structuration afin d'obtenir une vision cohérente et exploitable des opérations.

Par ailleurs, les besoins de suivi varient selon les utilisateurs. Les équipes internes ont besoin d'indicateurs consolidés pour le pilotage opérationnel, le contrôle et la validation de certaines situations. Les superviseurs côté client ont plutôt besoin d'une consultation ciblée sur les magasins qui leur sont affectés et sur les informations d'exécution les plus pertinentes. Cette différence d'usage montre la nécessité de proposer des restitutions adaptées à chaque besoin.

La problématique du projet peut donc être formulée comme suit :

Comment concevoir une solution data-driven permettant de centraliser, structurer et exploiter les données de merchandising terrain du projet Unilever, afin de faciliter le pilotage interne, la consultation client et le suivi des situations nécessitant une validation opérationnelle ?

VI. Objectifs du projet

L'objectif général du projet est de concevoir une solution data-driven permettant d'améliorer le suivi et l'analyse des opérations de merchandising terrain du projet Unilever chez Smollan Morocco.

Pour atteindre cet objectif, plusieurs objectifs spécifiques ont été définis :

- mettre en place un pipeline ETL permettant d'extraire, transformer et charger les données issues des fichiers *Data Dump* et *Coverage* ;
- centraliser les données dans une base MySQL afin de structurer l'historique des visites, des magasins, des merchandisers, des produits et des tâches exécutées ;
- concevoir des tableaux de bord Power BI permettant de suivre les indicateurs opérationnels et d'accompagner le pilotage interne ;
- mettre en place une interface de consultation orientée client permettant aux superviseurs Unilever de consulter les magasins qui leur sont affectés ;
- mettre en place un portail back-office interne destiné à l'analyse des validations opérationnelles et des situations nécessitant une vérification ;
- préparer une architecture évolutive pouvant intégrer progressivement de nouvelles règles de validation, de nouvelles vues analytiques et de nouvelles sources de données.

Ces objectifs traduisent la volonté de passer d'une exploitation principalement basée sur des fichiers et reportings séparés vers une solution structurée, centralisée et adaptée aux différents usages métier.

VII. Méthodologie de travail

VII.1 Démarche adoptée

La réalisation du projet a été conduite selon une démarche progressive et itérative. Cette approche a permis de partir de la compréhension du contexte métier avant de passer à l'analyse des données, à la conception de la solution, à la mise en place progressive des différentes composantes et aux ajustements nécessaires.

La première étape a consisté à comprendre le fonctionnement opérationnel du projet Unilever. Cette phase a porté sur l'identification des acteurs impliqués, des outils utilisés sur le terrain, des types de visites réalisées, ainsi que des reportings produits à partir des données collectées. Elle a permis de mieux cerner le rôle des données dans le suivi quotidien des opérations.

La deuxième étape a concerné l'analyse des sources de données disponibles, notamment les fichiers *Data Dump* et *Coverage*. L'objectif était de comprendre la structure de ces fichiers, la signification des champs, leur complémentarité et leur potentiel d'exploitation pour le suivi opérationnel et analytique.

La troisième étape a porté sur la conception progressive de la solution. Le travail a été organisé par couches fonctionnelles, en commençant par la structuration des données, puis la restitution analytique, avant d'aborder les interfaces de consultation et de validation. Cette organisation a permis de garder une cohérence entre les besoins métier et les choix techniques.

La dernière étape a été consacrée aux tests, aux ajustements et à la documentation. Les résultats obtenus ont été vérifiés à partir des données réelles afin de contrôler la cohérence des indicateurs, la fiabilité des transformations et l'utilité des restitutions proposées. La rédaction du rapport a été menée en parallèle avec l'avancement du projet afin de documenter progressivement le contexte, les choix effectués, les résultats obtenus, les limites rencontrées et les perspectives d'amélioration.

VII.2 Phases du projet

Afin de structurer le travail, le projet a été organisé en plusieurs phases complémentaires. Ces phases décrivent la progression suivie durant le stage, depuis la compréhension du contexte métier jusqu'aux tests et à la documentation. Elles couvrent l'analyse des fichiers sources, la structuration des données, la restitution des indicateurs et les ajustements réalisés à partir des résultats observés. La figure suivante synthétise les principales étapes de la démarche adoptée durant le projet.




Figure 1.6 Phases principales de réalisation du projet.

Cette organisation met en évidence une progression logique, allant de la compréhension du besoin métier vers l'exploitation des données et la restitution des résultats. Elle permet également de garder une cohérence entre les besoins opérationnels identifiés et les composantes proposées dans la solution.

VII.3 Planification du projet

La planification du projet doit permettre de situer les principales étapes de travail dans le temps. Elle repose sur une progression structurée depuis le cadrage métier jusqu'aux tests et à la rédaction du rapport.

La figure suivante accompagne la présentation de la planification générale du projet.



Figure 1.7 Illustration de la planification générale du projet

La planification du projet couvre les principales étapes de réalisation, depuis la compréhension du contexte métier jusqu'aux tests et à la rédaction du rapport. Elle inclut notamment l'analyse des fichiers *Data Dump* et *Coverage*, la structuration des données, la restitution des indicateurs, la mise en place des interfaces de consultation et les ajustements réalisés au cours du stage.

VIII. Conclusion

Ce chapitre a présenté le cadre général du Projet de Fin d'Études, en introduisant l'organisme d'accueil, le client Unilever ainsi que le contexte métier du merchandising terrain. Il a également permis de formuler la problématique du projet et de préciser les objectifs poursuivis.

Le projet s'inscrit dans une démarche de valorisation des données terrain, visant à mieux structurer les informations issues des opérations de merchandising et à proposer des outils adaptés aux besoins des différents utilisateurs. Le chapitre suivant sera consacré à l'analyse de l'existant et des besoins, afin de détailler le fonctionnement actuel du processus et les limites qui justifient la solution proposée.

CHAPITRE 2 : ÉTAT DE L'EXISTANT ET CADRE THÉORIQUE

I. Introduction

Ce chapitre présente l'état de l'existant relatif au suivi des opérations terrain du projet Unilever. Il décrit le fonctionnement actuel du processus de reporting, les principales sources de données exploitées, ainsi que les rapports produits à partir des exports issus de la plateforme Smollan.

Il introduit également les notions nécessaires à la compréhension du contexte métier, notamment le merchandising terrain, les indicateurs de suivi opérationnel et l'exploitation des données issues des visites en magasin. Cette présentation permet de situer les données utilisées dans leur environnement réel avant d'analyser les limites du fonctionnement actuel.

L'objectif de ce chapitre est d'identifier les difficultés rencontrées dans l'exploitation des données terrain et de dégager les besoins auxquels la solution proposée doit répondre. Cette analyse constitue une étape de transition entre le cadrage général du projet et la conception de la solution retenue.

II. Cadre théorique du projet

II.1 Merchandising terrain et exécution en point de vente

Le merchandising terrain désigne l'ensemble des actions réalisées en magasin afin d'assurer une bonne présentation des produits et une exécution conforme aux standards définis. Il concerne notamment la disponibilité des produits, leur visibilité en rayon, leur placement, la qualité d'exécution et le respect des consignes commerciales.

Dans le cadre des opérations suivies par Smollan, ces actions sont réalisées par des merchandisers lors des visites en point de vente. Les informations collectées peuvent inclure les réponses aux tâches, les photos justificatives, les relevés liés aux produits, les données de localisation et les éléments nécessaires au reporting. Ces données permettent de vérifier l'état réel de l'exécution terrain et d'alimenter les analyses opérationnelles.

II.2 Indicateurs de suivi opérationnel

Le pilotage des opérations de merchandising terrain repose sur plusieurs indicateurs permettant de mesurer l'avancement des visites, la qualité de l'exécution en magasin et la disponibilité des produits. Dans le cadre du projet Unilever, ces indicateurs sont utilisés pour le suivi interne des opérations, la préparation des reportings destinés au client et l'identification des situations nécessitant une vérification.

II.2.1 Taux de couverture

Le taux de couverture constitue l'un des indicateurs fondamentaux du suivi des opérations terrain. Il mesure la capacité des équipes merchandising à couvrir les points de vente planifiés durant une période donnée.

Dans le cadre du projet Unilever, cet indicateur est principalement exploité à partir du fichier *Coverage*, qui permet de suivre les visites planifiées, réalisées, non visitées, rejetées ou en déviation.

La formulation mathématique du taux de couverture est donnée par :

$$\text{Coverage Rate} = \frac{N_{\text{executed_visits}}}{N_{\text{planned_visits}}} \times 100$$

où :

- $N_{\text{executed_visits}}$ représente le nombre de visites réellement exécutées ;
- $N_{\text{planned_visits}}$ représente le nombre de visites prévues dans le plan de couverture.

Un faible taux de couverture peut traduire généralement :

- des magasins planifiés mais non visités ;
- des contraintes terrain ou organisationnelles ;
- un écart entre le planning prévu et l'exécution réelle.

II.2.2 Taux de déviation

La déviation correspond à un écart entre le plan d'exécution prévu et l'exécution réellement observée sur le terrain. Elle permet d'identifier les situations où la visite ne respecte pas totalement le planning ou les conditions attendues.

Dans le suivi opérationnel, le taux de déviation permet de mesurer la part des visites en déviation par rapport aux visites planifiées.

La formulation mathématique du taux de déviation est donnée par :

$$\text{Deviation Rate} = \frac{N_{\text{deviation_visits}}}{N_{\text{planned_visits}}} \times 100$$

où :

- $N_{\text{deviation_visits}}$ représente le nombre de visites signalées en déviation ;
- $N_{\text{planned_visits}}$ représente le nombre total de visites planifiées.

Une augmentation du taux de déviation peut indiquer :

- un écart entre la planification et l'exécution terrain ;
- des visites nécessitant une justification ;
- un besoin de suivi opérationnel par les équipes internes.

II.2.3 Taux de rejet

Le taux de rejet permet de suivre les visites qui n'ont pas été validées dans le processus opérationnel. Une visite rejetée peut être liée à une information incomplète, à une incohérence dans les données remontées ou à un problème de conformité avec les règles de suivi.

La formulation mathématique du taux de rejet est donnée par :

$$\text{Rejection Rate} = \frac{N_{\text{rejected_visits}}}{N_{\text{executed_visits}}} \times 100$$

où :

- $N_{\text{rejected_visits}}$ représente le nombre de visites rejetées ;
- $N_{\text{executed_visits}}$ représente le nombre total de visites exécutées.

Un taux de rejet élevé peut traduire généralement :

- des problèmes dans la qualité des informations saisies ;
- des visites nécessitant une correction ou une justification ;
- un besoin de validation ou de contrôle interne plus approfondi.

II.2.4 Disponibilité produit : OSA

L'OSA, ou *On Shelf Availability*, représente la disponibilité effective des produits en rayon au moment de la visite. Cet indicateur est important dans le merchandising, car il permet de vérifier si les références contrôlées sont bien présentes dans le point de vente.

Dans le cadre du projet Unilever, l'OSA constitue un indicateur clé pour les reportings client et pour l'identification des situations nécessitant une validation métier.

La formulation mathématique de l'OSA est donnée par :

$$\text{OSA} = \frac{N_{\text{available_products}}}{N_{\text{checked_products}}} \times 100$$

où :

- $N_{\text{available_products}}$ représente le nombre de produits disponibles en rayon ;
- $N_{\text{checked_products}}$ représente le nombre total de produits contrôlés.

Un faible niveau d'OSA peut traduire généralement :

- une rupture ou une absence de produit en rayon ;
- une exécution non conforme au niveau du point de vente ;
- une situation nécessitant une analyse ou une action corrective.

II.2.5 Visibilité en rayon : SOS

Le SOS, ou *Share of Shelf*, représente la part d'espace occupée par une marque ou une catégorie dans le linéaire. Il permet d'évaluer la visibilité des produits en magasin par rapport à l'espace total disponible dans la catégorie concernée.

La formulation mathématique du SOS est donnée par :

$$\text{SOS} = \frac{\text{ShelfSpace}_{\text{brand}}}{\text{ShelfSpace}_{\text{category}}} \times 100$$

où :

- $\text{ShelfSpace}_{\text{brand}}$ représente l'espace occupé par la marque ;
- $\text{ShelfSpace}_{\text{category}}$ représente l'espace total de la catégorie.

Une amélioration du SOS peut contribuer à :

- renforcer la visibilité des produits en rayon ;
- améliorer la présence de la marque dans la catégorie ;
- soutenir l'analyse de la qualité d'exécution en magasin.

II.2.6 Planogramme et placements

Le planogramme représente l'organisation attendue des produits dans le linéaire. Il permet de définir l'emplacement des références, leur ordre de présentation et leur disposition dans le rayon selon des règles merchandising précises.

Le placement primaire correspond à l'emplacement principal du produit dans le rayon. Le placement secondaire concerne les espaces additionnels permettant de renforcer la visibilité, tels que les têtes de gondole, les zones promotionnelles ou les emplacements spécifiques.

Le respect du planogramme et des placements permet généralement :

- d'assurer une présentation cohérente des produits ;
- d'améliorer la visibilité en point de vente ;
- de vérifier la conformité de l'exécution terrain avec les standards attendus.

Dans le cadre du projet, ces informations sont principalement exploitées à partir du fichier *Data Dump*, qui contient les réponses renseignées par les merchandisers lors des visites.

II.2.7 Taux de complétion des tâches

Le taux de complétion des tâches permet d'évaluer la part des tâches effectivement renseignées par rapport aux tâches attendues lors d'une visite. Il donne une indication sur le niveau de complétude des informations collectées par les merchandisers.

La formulation mathématique du taux de complétion des tâches est donnée par :

$$\text{Task Completion Rate} = \frac{N_{\text{completed_tasks}}}{N_{\text{expected_tasks}}} \times 100$$

où :

- $N_{\text{completed_tasks}}$ représente le nombre de tâches réalisées ou renseignées ;
- $N_{\text{expected_tasks}}$ représente le nombre total de tâches attendues.

Un faible taux de complétion peut indiquer :

- des informations terrain incomplètes ;
- des tâches non renseignées lors de la visite ;
- une difficulté à produire des indicateurs fiables pour le suivi et l'analyse.

Ainsi, les indicateurs de suivi opérationnel permettent de dépasser la simple mesure du nombre de visites réalisées. Ils offrent une lecture plus complète de l'exécution terrain, en combinant l'avancement des visites, la disponibilité produit, la visibilité en rayon, la conformité merchandising et la qualité des données collectées.

II.3 Exploitation des données terrain

Les données terrain ne peuvent pas être exploitées efficacement lorsqu'elles restent dispersées dans plusieurs fichiers ou rapports séparés. Avant leur utilisation dans des tableaux de bord ou dans des interfaces de consultation, elles doivent être nettoyées, structurées et centralisées dans un modèle cohérent.

Cette centralisation permet de conserver un historique exploitable, de rapprocher les informations issues de différentes sources et de produire des indicateurs fiables. Elle facilite également la distinction entre les usages internes et les usages orientés client. Les tableaux de bord servent au pilotage et à l'analyse, les interfaces de consultation permettent un accès ciblé aux informations par les utilisateurs concernés, tandis que le portail back-office reste destiné aux validations et contrôles internes.

Après avoir présenté ces notions générales, il convient d'analyser le fonctionnement actuel du suivi opérationnel afin d'identifier les limites auxquelles la solution proposée doit répondre.

III. Processus actuel de suivi opérationnel

Dans le cadre du projet Unilever, le suivi des activités terrain repose initialement sur les données issues de la plateforme opérationnelle utilisée par Smollan. Les merchandisers réalisent leurs visites à travers l'application terrain, dans laquelle ils renseignent les informations liées à l'exécution en magasin : présence au point de vente, tâches réalisées, réponses aux questionnaires, disponibilité des produits, éléments de qualité, photos justificatives et données de localisation.

Le processus actuel s'appuie principalement sur l'extraction quotidienne de fichiers Excel depuis la plateforme Smollan. Ces exports permettent de suivre l'activité de la veille ou d'une période sélectionnée. Les deux fichiers les plus importants dans ce processus sont le fichier *Data Dump* et le fichier *Coverage*. Le premier regroupe les détails d'exécution saisis sur le terrain, tandis que le second apporte une vision plus opérationnelle de la couverture, des visites planifiées, des visites réalisées, des visites adhoc, des rejets, des déviations et des magasins non visités.

Ces fichiers sont exploités pour produire différents reportings. Certains sont orientés vers le suivi interne, notamment les rapports de couverture, de déviation, de visites rejetées et de magasins non visités. D'autres sont destinés au client Unilever, comme le suivi OSA transmis quotidiennement, ainsi que des reportings plus spécifiques ou périodiques liés à la qualité d'exécution, au SOS, au placement en rayon ou à d'autres indicateurs terrain. Ces reportings permettent de suivre l'état d'avancement des opérations, d'analyser la disponibilité des produits, d'identifier les magasins nécessitant un suivi particulier et de faciliter les actions de suivi.

Ce processus permet d'assurer un suivi quotidien des opérations. Toutefois, il reste fortement dépendant des exports Excel et de traitements séparés. Les informations nécessaires à l'analyse sont présentes, mais elles sont dispersées entre plusieurs fichiers et rapports. De plus, le fichier *Data Dump* ne suffit pas à lui seul pour reconstituer toute la situation opérationnelle, car certaines informations liées aux visites planifiées, non réalisées ou rejetées sont principalement disponibles dans le fichier *Coverage*. Cette situation rend plus difficile la constitution d'un historique structuré, l'accès rapide aux détails d'exécution d'un magasin et la mise en place d'indicateurs consolidés pour le pilotage opérationnel.

La figure suivante présente une vue simplifiée du processus actuel de reporting, depuis la

saisie des informations terrain dans l'application Smart 3 jusqu'à la production des rapports internes et des reportings destinés au client Unilever.




Figure 2.1 Processus actuel de reporting merchandising basé sur Smart 3 et les exports Excel

Cette figure montre que les exports issus du portail Smollan constituent le point de départ de plusieurs usages. Les rapports internes sont principalement orientés vers le suivi opérationnel, notamment la couverture, les déviations, les rejets et les justifications terrain. Les reportings destinés au client Unilever sont davantage orientés vers la disponibilité produit, la qualité d'exécution, le SOS, le planogramme et les analyses hebdomadaires ou mensuelles.

IV. Sources de données exploitées

IV.1 Fichier Data Dump

Le fichier *Data Dump* constitue la source principale des données détaillées issues de l'exécution terrain. Il contient les réponses renseignées par les merchandisers lors de leurs visites en magasin, ainsi que les informations associées aux tâches exécutées.

Ce fichier regroupe notamment les données relatives aux merchandisers, aux magasins, aux produits, aux catégories, aux tâches, aux questions posées et aux réponses saisies. Il contient également des informations liées aux dates d'exécution, aux coordonnées de localisation collectées par l'application terrain et, dans certains cas, aux liens vers les photos justificatives.

Dans le cadre du projet, le *Data Dump* permet d'analyser plusieurs dimensions de l'exécution merchandising, telles que l'OSA, la qualité d'exécution, le placement primaire, le placement secondaire, le SOS, les relevés de prix, les conditions magasin ainsi que les opérations de check-in et check-out. Il représente donc une source riche pour comprendre ce qui a été réellement renseigné sur le terrain.

Toutefois, cette richesse s'accompagne d'une certaine complexité. Les données sont organisées sous forme de lignes de réponses, avec des tâches, des questions et des formats variables selon les cas. Cette structure nécessite un traitement de transformation afin de construire des tables exploitables pour l'analyse, la validation et la restitution dans les tableaux de bord.

IV.2 Fichier Coverage

Le fichier *Coverage* apporte une vision plus synthétique et opérationnelle de l'activité terrain. Contrairement au *Data Dump*, qui décrit principalement les réponses et les tâches renseignées lors des visites, le fichier *Coverage* permet de suivre l'état des visites prévues et réalisées.

Il contient notamment les informations liées aux visites planifiées, aux visites exécutées, aux visites adhoc, aux visites rejetées, aux déviations, aux magasins non visités, aux merchandisers, aux superviseurs, aux formats de magasins, aux villes, aux régions, ainsi qu'à certaines informations de durée et de localisation.

Ce fichier est essentiel pour le calcul des indicateurs opérationnels, notamment le taux de couverture, le nombre de visites exécutées, les visites non réalisées, les rejets, les déviations et l'activité des merchandisers sur une période donnée. Il permet également d'alimenter les vues de suivi utilisées dans les tableaux de bord et dans l'application mobile.

Ainsi, le fichier *Coverage* joue un rôle central dans la compréhension de l'état d'avancement du terrain, car il permet de relier la planification des visites à leur réalisation effective.

IV.3 Complémentarité Data Dump / Coverage

Les fichiers *Data Dump* et *Coverage* sont complémentaires. Le *Data Dump* permet d'analyser le contenu détaillé des visites exécutées, tandis que le *Coverage* permet de reconstituer la vision opérationnelle globale des visites planifiées, réalisées, rejetées ou non effectuées.

Cette complémentarité est importante, car l'analyse de l'exécution terrain ne peut pas reposer uniquement sur les réponses détaillées des tâches. Par exemple, un magasin non visité ou une visite rejetée peut ne pas disposer du même niveau de détail dans le *Data Dump*, alors

que ces informations sont indispensables pour le suivi opérationnel. Le fichier *Coverage* permet donc de compléter cette lecture en apportant le statut des visites et les informations de couverture.

Dans le cadre de la solution proposée, l'exploitation conjointe de ces deux sources permet de construire une base de données plus cohérente. Les données détaillées issues du *Data Dump* alimentent les tables de tâches et les réponses normalisées, tandis que les données du *Coverage* alimentent les indicateurs de suivi opérationnel. Cette approche permet d'obtenir une vision à la fois détaillée et globale des activités terrain.

Le tableau suivant synthétise le rôle de chaque source dans la solution proposée.

Tableau 2.1 Comparaison entre les fichiers *Data Dump* et *Coverage*

Fichier	Type d'information	Utilité dans le projet	Limite principale
<i>Data Dump</i>	Données détaillées d'exécution terrain : tâches, questions, réponses, produits, photos et informations de localisation.	Analyse du contenu des visites réalisées : réponses OSA, qualité d'exécution, placement en rayon, SOS et autres tâches terrain.	Ne permet pas à lui seul de reconstituer toute la situation opérationnelle, notamment les visites non réalisées ou certains statuts de couverture.
<i>Coverage</i>	Données de suivi opérationnel : visites planifiées, visites réalisées, visites adhoc, rejets, déviations, magasins non visités et informations de supervision.	Calcul des KPI de couverture, suivi de l'avancement terrain et alimentation des vues de pilotage opérationnel.	Ne fournit pas toujours le détail complet des réponses terrain et des tâches exécutées, principalement disponibles dans le <i>Data Dump</i> .

Cette comparaison montre que les deux fichiers répondent à des besoins différents. Le *Data Dump* apporte le détail de l'exécution terrain, tandis que le *Coverage* permet de suivre l'état global des visites. Leur combinaison constitue donc une base nécessaire pour construire une lecture fiable des opérations.

V. Rapports existants

Les fichiers exportés depuis la plateforme Smollan servent de base à plusieurs reportings utilisés dans le suivi des opérations terrain. Ces reportings peuvent être regroupés en deux grandes catégories : les rapports destinés au suivi interne des opérations et les rapports destinés au client Unilever.

V.1 Rapports internes Smollan

Les rapports internes sont principalement orientés vers le suivi opérationnel quotidien. Ils permettent de suivre l'état de couverture, les visites réalisées, les visites non effectuées, les déviations, les rejets et certains éléments liés à l'assiduité ou au temps de production. Ces rapports facilitent la lecture de l'activité terrain et permettent d'identifier les situations nécessitant un suivi opérationnel.

Parmi les rapports internes les plus utilisés, on retrouve notamment les rapports de couverture et les rapports de déviation. Le rapport de couverture permet d'obtenir une vision de l'avancement des visites, tandis que le rapport de déviation met en évidence les magasins nécessitant une confirmation, une justification ou une revisite selon le contexte terrain.

Ces reportings jouent donc un rôle important dans la coordination quotidienne des opérations. Toutefois, ils restent généralement produits sous forme de fichiers séparés, ce qui limite l'analyse historique et la centralisation des informations dans une seule base exploitable.

V.2 Rapports destinés au client Unilever

En parallèle des rapports internes, certaines restitutions sont destinées au client Unilever. Elles concernent principalement la qualité d'exécution en magasin, la disponibilité des produits et certains indicateurs liés à la visibilité ou à la présence des produits en rayon.

Le suivi OSA constitue un exemple important de reporting client, car il permet d'analyser la disponibilité des produits dans les magasins visités. D'autres reportings, comme les rapports liés à la qualité d'exécution, au SOS, au placement en rayon ou à d'autres indicateurs terrain, peuvent être produits de manière périodique ou selon les besoins du suivi opérationnel.

Ces rapports permettent au client de disposer d'une lecture sur l'exécution terrain et sur les points nécessitant une attention particulière. Cependant, comme pour les rapports internes, leur exploitation reste dépendante des fichiers sources et des traitements réalisés en amont.

Le tableau suivant résume les principaux types de reportings produits à partir des fichiers opérationnels.

Tableau 2.2 Synthèse des reportings existants

Type de rapport	Destinataire	Fréquence	Objectif principal
Rapport de couverture	Suivi interne	Quotidienne	Suivre l'avancement des visites, les magasins couverts, les magasins non visités et l'état global du terrain.
Rapport de déviation	Suivi interne	Quotidienne ou selon le besoin	Identifier les magasins nécessitant une confirmation, une justification ou une action de suivi.
Suivi OSA	Client Unilever	Quotidienne	Suivre la disponibilité des produits et identifier les références non disponibles en magasin.
Rapports qualité, SOS et placement	Client Unilever	Périodique ou selon le besoin	Analyser la qualité d'exécution, la présence produit, le placement en rayon et les points nécessitant une attention particulière.

Ce tableau montre que les reportings existants répondent à des besoins complémentaires. Les rapports internes soutiennent le pilotage quotidien des opérations, tandis que les reportings destinés au client permettent de suivre la disponibilité, la qualité d'exécution et la visibilité des produits en magasin.

VI. Limites du processus actuel

Le processus actuel permet d'assurer un suivi quotidien des opérations terrain, mais il présente plusieurs limites lorsque les volumes de données augmentent et lorsque les besoins d'analyse deviennent plus avancés. La première limite concerne la dépendance aux fichiers Excel exportés depuis la plateforme. Ces fichiers restent indispensables au suivi opérationnel, mais leur exploitation sous forme de rapports séparés rend plus difficile la centralisation de l'information et la construction d'une vision historique consolidée.

La deuxième limite concerne la dispersion des données entre plusieurs sources. Le fichier *Data Dump* contient les détails d'exécution, tandis que le fichier *Coverage* apporte les informations de couverture et de statut des visites. Cette complémentarité est nécessaire, mais elle impose un travail de rapprochement afin de produire des indicateurs fiables. Sans modèle de données centralisé, l'analyse peut devenir répétitive et dépendante de traitements manuels ou semi-automatisés.

Une autre limite concerne l'accès aux détails d'exécution par magasin. Les rapports exis-

tants permettent de suivre l'état global des opérations, mais l'accès rapide à l'historique d'un magasin, aux tâches exécutées, aux réponses terrain ou aux éléments justificatifs reste moins direct. Cette situation limite la capacité à consulter facilement une vision détaillée et structurée de l'exécution terrain.

Enfin, les besoins de suivi ne sont pas identiques selon les utilisateurs. Les équipes internes ont besoin d'indicateurs de pilotage, de contrôle et de validation opérationnelle, tandis que les superviseurs côté client doivent disposer d'une consultation plus ciblée sur les magasins qui leur sont affectés. Cette différence d'usage montre la nécessité de distinguer les couches de restitution : tableaux de bord BI pour le pilotage, interface de consultation client pour l'accès aux magasins affectés, et portail back-office pour le suivi interne des validations.

VII. Besoins fonctionnels

À partir des limites identifiées dans le processus actuel, plusieurs besoins fonctionnels ont été définis afin de structurer la solution proposée. Ces besoins concernent à la fois la centralisation des données, le suivi des indicateurs opérationnels, la consultation des informations terrain et la validation interne des situations nécessitant une analyse complémentaire.

Le premier besoin consiste à mettre en place une base de données centralisée capable de regrouper les informations issues des fichiers *Data Dump* et *Coverage*. Cette base doit permettre de conserver l'historique des données, de structurer les informations relatives aux visites, aux magasins, aux merchandisers, aux produits et aux tâches exécutées, et de faciliter leur exploitation dans les différentes couches de la solution.

Le deuxième besoin concerne la mise à disposition de tableaux de bord décisionnels permettant de suivre l'avancement des opérations terrain et d'analyser les principaux indicateurs avant la restitution finale. Ces tableaux de bord doivent aider au pilotage interne et au management, tout en facilitant la lecture des données liées à la couverture, à l'activité des merchandisers et à certains reportings client comme l'OSA, la qualité d'exécution, le SOS ou le placement en rayon.

Le troisième besoin concerne la mise en place d'une interface de consultation orientée client. Cette interface doit permettre aux superviseurs côté Unilever de consulter les magasins qui leur sont affectés. L'objectif est de leur offrir une visibilité simple et ciblée sur l'exécution terrain, les informations des magasins, les dernières visites et les détails liés aux tâches exécutées.

Le quatrième besoin porte sur la mise en place d'un portail back-office interne destiné au suivi des validations opérationnelles. Ce portail doit permettre d'exploiter les résultats des règles de validation, notamment les cas liés à l'OSA, aux contrôles GPS ou à d'autres situations nécessitant une vérification. Il doit constituer un espace interne de consultation, d'analyse et, à terme, de suivi des actions correctives.

Ainsi, les besoins fonctionnels du projet ne se limitent pas à la production de tableaux de bord. Ils couvrent l'ensemble de la chaîne d'exploitation de la donnée, depuis l'ingestion des fichiers jusqu'à la restitution des informations sous forme de tableaux de bord, d'interface de

consultation client et de portail de validation interne.

VIII. Besoins techniques

La mise en œuvre de la solution nécessite une architecture technique capable de traiter des fichiers Excel volumineux, de structurer les données et de les rendre exploitables par plusieurs outils. Le premier besoin technique concerne la mise en place d'un pipeline ETL développé en Python, permettant d'extraire, nettoyer, transformer et charger les données issues des fichiers *Data Dump* et *Coverage*.

Le deuxième besoin concerne la centralisation des données dans une base MySQL. Cette base doit permettre de stocker les informations opérationnelles, les réponses terrain, les tables liées aux différentes tâches, ainsi que les indicateurs nécessaires aux tableaux de bord, aux interfaces de consultation et au portail de validation.

Le troisième besoin porte sur la restitution et l'intégration des données. Les tableaux de bord sont réalisés avec Power BI afin de faciliter l'analyse et le pilotage des indicateurs. Les interfaces de consultation et de validation s'appuient sur des services applicatifs permettant d'interroger la base de données et de restituer les informations nécessaires aux utilisateurs concernés.

Enfin, la solution doit rester évolutive afin de permettre l'ajout progressif de nouvelles règles de validation, de nouvelles vues analytiques, de nouveaux fichiers sources comme les Masters, ainsi que des mécanismes d'authentification et de gestion des rôles plus avancés.

IX. Conclusion

Ce chapitre a permis d'introduire les notions nécessaires à la compréhension du projet, notamment le merchandising terrain, les indicateurs de suivi opérationnel et l'exploitation structurée des données collectées en magasin. Ces éléments théoriques ont posé le cadre métier et technique dans lequel s'inscrit la solution proposée.

L'état de l'existant a ensuite permis d'analyser le fonctionnement actuel du suivi des opérations terrain dans le cadre du projet Unilever. L'étude du processus actuel a montré que les fichiers *Data Dump* et *Coverage* constituent deux sources complémentaires : le premier apporte le détail de l'exécution terrain, tandis que le second permet de suivre la couverture et le statut opérationnel des visites.

L'analyse des rapports existants a également mis en évidence la diversité des usages des données, entre le suivi interne des opérations et les reportings destinés au client Unilever. Malgré l'utilité de ce fonctionnement, plusieurs limites ont été identifiées, notamment la dépendance aux fichiers Excel, la dispersion des informations, la difficulté de constituer un historique centralisé et la nécessité d'adapter les restitutions selon les utilisateurs.

Ces constats ont permis de définir les principaux besoins fonctionnels et techniques du pro-

jet. Ils justifient la mise en place d'une solution data-driven reposant sur une base de données centralisée, des tableaux de bord décisionnels, une interface de consultation orientée client et un portail back-office de validation interne. Le chapitre suivant présentera la conception globale de cette solution ainsi que son architecture fonctionnelle et technique.

CHAPITRE 3 : CONCEPTION GLOBALE DE LA SOLUTION

I. Introduction

Après l'analyse de l'existant, des sources de données et des besoins identifiés, ce chapitre présente la conception globale de la solution proposée. L'objectif est de décrire l'organisation générale de la solution avant de détailler, dans les chapitres suivants, ses différentes composantes techniques et fonctionnelles.

La solution retenue repose sur une approche data-driven permettant de structurer les données issues des opérations de merchandising terrain, de les centraliser dans une base cohérente et de les exploiter à travers plusieurs supports de restitution. Cette conception vise à répondre aux besoins de suivi interne, de consultation orientée client et de validation opérationnelle.

Ce chapitre présente d'abord la vision générale de la solution, puis son architecture globale. Il décrit ensuite les principales couches fonctionnelles retenues, à savoir la couche d'acquisition et de traitement des données, la couche centrale de données, la couche Business Intelligence, l'interface de consultation client et le portail back-office interne. Enfin, il introduit les principaux choix technologiques adoptés dans le cadre du projet.

II. Vision générale de la solution

La solution proposée vise à transformer les données issues des fichiers *Data Dump* et *Coverage* en informations structurées, exploitables et adaptées aux différents besoins de suivi. Elle ne remplace pas le processus métier existant, mais vient le compléter en apportant une meilleure organisation des données, une centralisation de l'historique et une restitution plus claire des indicateurs opérationnels.

La vision générale de la solution repose sur une chaîne de traitement allant de l'extraction des fichiers opérationnels jusqu'à la restitution des résultats. Les fichiers exportés depuis la plateforme Smollan sont d'abord analysés, nettoyés et transformés à travers un processus de traitement des données. Les informations pertinentes sont ensuite chargées dans une base de données relationnelle, qui constitue le socle central de la solution.

À partir de cette base, plusieurs usages sont rendus possibles. Les tableaux de bord permettent aux équipes internes de suivre les indicateurs de performance et l'avancement des opérations. L'interface de consultation orientée client permet aux superviseurs concernés d'accéder aux informations liées aux magasins qui leur sont affectés. Le back-office interne permet quant à lui de consulter les résultats des règles de validation et de suivre les situations nécessitant une vérification.

Cette organisation permet de distinguer les usages tout en conservant une même base de

données centrale. Elle assure ainsi une cohérence entre les données utilisées pour le pilotage, la consultation et la validation opérationnelle.

III. Architecture globale

L'architecture globale de la solution a été conçue autour d'une chaîne de traitement allant de la collecte des données terrain jusqu'à leur exploitation par les différents utilisateurs. Elle met en relation les sources opérationnelles, les mécanismes d'acquisition des fichiers, le pipeline de traitement, la base de données centrale et les couches de restitution.




Figure 3.1 Architecture globale de la solution data-driven

La figure 3.1 présente l'organisation générale de la solution proposée. Les données sont d'abord collectées sur le terrain par les merchandisers à travers l'application Smart 3, puis synchronisées avec le portail Smollan. À partir de ce portail, deux modes d'acquisition sont pris en compte : l'utilisation de fichiers Excel déjà disponibles localement et l'automatisation de l'export via Playwright. Ces deux modes alimentent les mêmes fichiers d'entrée, à savoir le *Data Dump* et le *Coverage*.

La partie centrale de l'architecture repose sur un pipeline orchestré par Prefect. Ce pipeline organise les étapes de traitement, de contrôle et de chargement des données. Les fichiers d'entrée passent par une logique de traitement inspirée de l'architecture en médaille : une couche Bronze pour conserver les données brutes, une couche Silver pour nettoyer et structurer les données, puis une couche Gold pour produire des données prêtes à l'analyse. Une couche de validation complète ce processus en appliquant des règles métier permettant d'identifier certaines situations nécessitant une vérification opérationnelle.

Les données structurées ainsi que les résultats de validation sont ensuite centralisés dans une base MySQL. Cette base constitue le socle commun de la solution, car elle alimente à la

fois les tableaux de bord Power BI et les services applicatifs développés avec Spring Boot en Java. Ces services exposent des APIs REST consommées par l'interface mobile Expo / React Native et par le portail web back-office React.

IV. Séparation des couches fonctionnelles

L'architecture proposée repose sur une séparation des couches fonctionnelles afin de mieux organiser les responsabilités de chaque composante. Cette séparation permet de distinguer les étapes d'acquisition, de traitement, de centralisation, d'analyse et de restitution des données. Elle facilite également l'évolution progressive de la solution, car chaque couche peut être améliorée ou enrichie sans remettre en cause l'ensemble de l'architecture.

IV.1 Couche d'acquisition des données

La couche d'acquisition constitue le point d'entrée des données dans la solution. Elle repose sur les fichiers opérationnels issus du portail Smollan, principalement les fichiers *Data Dump* et *Coverage*. Deux modes d'acquisition sont pris en compte dans le projet : l'utilisation de fichiers Excel déjà disponibles localement et l'automatisation de l'export depuis le portail à l'aide de Playwright.

Cette couche permet donc de récupérer les fichiers nécessaires au traitement, tout en conservant une certaine flexibilité. Le traitement peut être lancé à partir de fichiers sélectionnés par chemin local, ou à partir de fichiers téléchargés automatiquement lorsque l'automatisation est utilisée.

IV.2 Couche d'orchestration et de Data Engineering

La couche d'orchestration et de Data Engineering représente le cœur technique de la solution. Elle organise les différentes étapes du pipeline de traitement, depuis l'ingestion des fichiers jusqu'à la préparation des données structurées. L'orchestration est assurée par Prefect, qui permet de contrôler l'exécution des étapes, de suivre les traitements et de faciliter la gestion des erreurs.

Le traitement des données est réalisé à l'aide de scripts Python, en s'appuyant notamment sur des bibliothèques adaptées au traitement de fichiers Excel et de données tabulaires. Cette couche assure le nettoyage, l'harmonisation, la transformation et la structuration des informations issues des fichiers sources. La logique adoptée distingue les données brutes, les données nettoyées et les données prêtes pour l'analyse ou la validation.

IV.3 Couche centrale de données

La couche centrale de données repose sur une base MySQL nommée *unilever_db*. Elle constitue le socle commun de la solution, car elle centralise les données nécessaires aux différents usages : reporting, consultation et validation opérationnelle.

Cette base permet de regrouper les informations de référence, les données opérationnelles, les réponses terrain, les tables liées aux tâches et les résultats de validation. Elle joue donc un rôle essentiel dans la consolidation de l'historique et dans la mise à disposition d'une source de données cohérente pour les autres couches de la solution.

IV.4 Couche Business Intelligence

La couche Business Intelligence est destinée à la restitution analytique des données. Elle permet de produire des tableaux de bord orientés vers le suivi des indicateurs opérationnels, tels que la couverture, les déviations, l'OSA, le SOS ou encore la performance des marchandises.

Dans le cadre du projet, cette couche vise principalement à faciliter la lecture des données par les équipes internes et à soutenir le pilotage opérationnel. Les tableaux de bord permettent ainsi d'obtenir une vision synthétique de l'activité terrain et d'identifier plus rapidement les situations nécessitant une attention particulière.

IV.5 Couche applicative de consultation et de validation

La couche applicative regroupe les interfaces de consultation et de validation. Elle s'appuie sur des services backend développés avec Spring Boot, qui permettent d'interroger la base de données et de fournir les informations nécessaires aux interfaces.

L'interface de consultation client, réalisée avec React Native et Expo Go, permet aux superviseurs Unilever de consulter les magasins qui leur sont affectés, ainsi que les informations liées à l'exécution terrain. Le portail back-office interne, développé avec React, est destiné au suivi des résultats de validation, notamment les anomalies OSA, les contrôles GPS et les situations nécessitant une revue opérationnelle.

Cette couche permet donc de distinguer les usages selon les profils concernés : consultation orientée client d'un côté, et validation interne de l'autre.

Après avoir présenté l'organisation fonctionnelle de la solution, il convient de préciser les principaux choix technologiques retenus pour mettre en œuvre ces différentes couches.

V. Choix technologiques

Les choix technologiques ont été définis en cohérence avec l'architecture globale de la solution. Chaque outil retenu intervient dans une couche précise du projet : acquisition des fichiers, orchestration du pipeline, traitement des données, centralisation, restitution analytique ou mise en place des interfaces de consultation et de validation.

V.1 Outils d'acquisition et d'orchestration



Playwright

Playwright a été retenu pour automatiser une partie de l'acquisition des fichiers depuis le portail Smollan. Il permet de reproduire certaines actions effectuées dans un navigateur, notamment l'accès au portail, l'application des filtres et le téléchargement des exports Excel. Dans le cadre du projet, il constitue un mode d'acquisition complémentaire à l'utilisation de fichiers déjà disponibles localement.



Prefect est utilisé pour orchestrer le pipeline de traitement des données. Son rôle est d'organiser l'exécution des différentes étapes, depuis la préparation des fichiers jusqu'au chargement des données et à l'exécution des règles de validation. Il permet ainsi de mieux structurer le flux de traitement, de suivre les exécutions et de faciliter la gestion des erreurs.

V.2 Outils de traitement et de structuration des données



Python

Python constitue le langage principal utilisé pour la mise en place du pipeline de traitement. Il permet de lire les fichiers sources, d'appliquer les transformations nécessaires, de préparer les données structurées et d'alimenter la base centrale. Son utilisation est adaptée au contexte du projet, qui repose sur des fichiers Excel, des traitements tabulaires et des règles métier évolutives.



La bibliothèque pandas est utilisée pour manipuler les données sous forme de tableaux. Elle permet de filtrer, nettoyer, harmoniser et transformer les données issues des fichiers *Data Dump* et *Coverage*. Elle joue un rôle central dans la préparation des données exploitables pour l'analyse, les indicateurs et les règles de validation.



openpyxl complète l'utilisation de pandas pour certaines opérations liées aux fichiers Excel. Cette bibliothèque permet d'interagir avec les classeurs Excel lorsque certaines manipulations nécessitent une lecture ou une gestion plus spécifique du format d'origine. Elle est donc utile dans un contexte où les données proviennent principalement d'exports opérationnels.

V.3 Outils de centralisation et de restitution analytique



MySQL a été retenu pour centraliser les données structurées du projet dans une base relationnelle. Cette base permet de regrouper les informations issues des fichiers sources, les données de référence, les tables analytiques et les résultats de validation. Elle constitue le socle commun utilisé par les tableaux de bord, les services applicatifs et les interfaces de consultation.



Power BI

Power BI est utilisé pour la restitution analytique des données. Il permet de construire des tableaux de bord destinés au suivi des indicateurs opérationnels, tels que la couverture, les déviations, l'OSA, le SOS ou encore la performance des marchandises. Ce choix répond au besoin de fournir une lecture synthétique et visuelle des données aux équipes internes.

V.4 Outils de la couche applicative




Java et Spring Boot

Java est utilisé pour le développement de la couche backend de la solution. Associé au framework Spring Boot, il permet de mettre en place des services applicatifs structurés et des APIs REST assurant l'accès aux données centralisées dans MySQL. Cette couche joue le rôle d'intermédiaire entre la base de données et les interfaces de restitution, notamment l'interface mobile Expo / React Native et le portail back-office React.



React Native et Expo Go

React Native, avec Expo Go, est utilisé pour l'interface mobile de consultation orientée client. Cette interface permet aux superviseurs Unilever de consulter les magasins qui leur sont affectés, ainsi que certaines informations liées à l'exécution terrain. Ce choix facilite la mise en place d'une interface mobile progressive et adaptée à la consultation des données opérationnelles.



React

React est utilisé pour le portail back-office interne. Cette interface web permet de consulter les résultats de validation, notamment les anomalies OSA, les contrôles GPS et les situations nécessitant une revue opérationnelle. Il permet de construire une interface interactive, adaptée au suivi interne et à l'évolution future du portail.

V.5 Synthèse des choix technologiques

L'ensemble de ces choix technologiques permet de couvrir les différentes couches de la solution. Playwright et Prefect interviennent dans l'acquisition et l'orchestration, Python, pandas et openpyxl assurent le traitement des données, MySQL centralise les informations, tandis que Power BI, Java/Spring Boot, React Native, Expo Go et React permettent de restituer et d'exposer les résultats selon les besoins des utilisateurs.

VI. Conclusion

Ce chapitre a présenté la conception globale de la solution proposée. Il a permis de décrire la vision générale du projet, l'architecture globale ainsi que les principales couches fonctionnelles qui composent la solution.

L'architecture retenue repose sur une séparation claire entre l'acquisition des données, l'orchestration des traitements, la structuration des données, la centralisation dans MySQL et les couches d'exploitation. Cette organisation permet de répondre aux besoins identifiés dans l'analyse de l'existant, tout en conservant une solution progressive et évolutive.

Les choix technologiques présentés montrent que la solution combine des outils de Data Engineering, de Business Intelligence et de développement applicatif. Le chapitre suivant sera consacré à la mise en place du pipeline Data Engineering, en détaillant les étapes d'ingestion, de transformation et de chargement des données issues des fichiers *Data Dump* et *Coverage*.

CHAPITRE 4 : DÉVELOPPEMENT DE LA SOLUTION ADOPTÉE

I. Introduction

Après avoir présenté la conception globale de la solution, ce chapitre décrit le développement des principales composantes retenues dans le cadre du projet. Il ne s'agit pas uniquement de présenter un pipeline de traitement, mais d'expliquer la mise en place progressive d'une solution complète permettant de structurer les données, de les centraliser, d'appliquer certaines règles de validation et de les rendre accessibles à travers des interfaces de restitution.

Le développement de la solution repose d'abord sur un pipeline Data Engineering permettant de transformer les fichiers opérationnels *Data Dump* et *Coverage* en données structurées et exploitables. Ces deux fichiers constituent les principales sources utilisées dans le projet : le premier apporte les réponses détaillées issues des visites terrain, tandis que le second fournit une vision opérationnelle des visites planifiées, réalisées, rejetées, déviées ou non effectuées.

À partir de ces données, la solution construit progressivement une base MySQL organisée autour de tables de référence, de tables opérationnelles, de tables dynamiques par tâche et d'une table normalisée *survey_responses*. Cette structuration permet ensuite d'alimenter les analyses, les tableaux de bord, les règles de validation et les interfaces applicatives.

Ce chapitre présente également la mise en place des règles de validation métier, notamment la distinction entre les contrôles appliqués aux formats MT et GT. Enfin, il introduit la couche applicative développée autour de services backend Spring Boot, d'une interface mobile de consultation client et d'un portail back-office interne.

II. Mise en place du pipeline Data Engineering

La figure suivante présente une vue simplifiée du flux général du pipeline Data Engineering mis en place dans le cadre du projet. Ce flux met en évidence les principales étapes du traitement, depuis l'acquisition des fichiers Excel jusqu'au chargement des données structurées dans MySQL. Il montre également le rôle de Prefect dans l'orchestration du pipeline, ainsi que la logique progressive de transformation des données à travers les couches Bronze, Silver et Gold.

E T L




Figure 4.1 Flux général du pipeline Data Engineering

Le pipeline commence par les fichiers sources *Data Dump* et *Coverage*, qui peuvent être fournis à partir d'un chemin local ou récupérés via l'export du portail. Les données sont ensuite lues et préparées à l'aide de scripts Python, puis structurées progressivement. La couche Bronze correspond à l'ingestion initiale des fichiers, la couche Silver regroupe les opérations de nettoyage et d'harmonisation, tandis que la couche Gold prépare les tables prêtes à l'exploitation. Les résultats sont enfin chargés dans la base MySQL afin d'alimenter les règles de validation, les jeux de données BI et les services backend.

II.1 Ingestion des fichiers Excel

L'ingestion constitue la première étape du pipeline Data Engineering. Elle consiste à récupérer les fichiers opérationnels nécessaires au traitement, principalement le fichier *Data Dump* et le fichier *Coverage*. Ces deux fichiers représentent les sources de base du projet : le *Data Dump* contient les réponses détaillées issues des visites terrain, tandis que le *Coverage* apporte une vision opérationnelle des visites planifiées, réalisées, rejetées, déviées ou non effectuées.

Afin de rendre le traitement flexible, deux modes d'entrée ont été prévus. Le premier mode repose sur l'utilisation de fichiers Excel déjà disponibles localement. Dans ce cas, l'utilisateur peut lancer le traitement en indiquant directement le chemin du fichier *Data Dump* et du fichier *Coverage*. Ce mode est utile lorsque les exports ont déjà été téléchargés depuis le portail et doivent simplement être retraités par le pipeline.

Le second mode repose sur l'automatisation de l'export depuis le portail Smollan. Cette approche utilise Playwright afin d'automatiser certaines actions réalisées habituellement dans un navigateur, telles que l'accès au portail, l'application des paramètres nécessaires et le téléchargement des fichiers Excel. Ce mode permet de réduire les manipulations manuelles répétitives, tout en conservant les fichiers exportés comme point d'entrée du pipeline.

II.1.1 Lancement du pipeline

Le pipeline est lancé depuis le terminal à partir de l'environnement virtuel du projet. Cette étape permet d'exécuter le module principal *main.py*, situé dans le dossier *data-engineering*. Le lancement de cette commande ouvre ensuite l'interface de sélection, à partir de laquelle l'utilisateur peut choisir les fichiers à traiter et le mode d'entrée souhaité.

```
(.venv) PS C:\Users\hamza\CHARMAQE\MySpace\merch-performance-app> python .\data-engineering\main.py
```

Figure 4.2 Commande de lancement du pipeline ETL

La figure 4.2 présente la commande utilisée pour démarrer le pipeline depuis le répertoire du projet. Cette commande constitue le point d'entrée de l'exécution avant la sélection des fichiers *Data Dump* et *Coverage*.

II.1.2 Interface de sélection des fichiers

Après le lancement de la commande, une interface graphique permet de configurer l'exécution du pipeline. Cette interface distingue les fichiers journaliers à traiter, à savoir le *Data Dump* et le *Coverage*. Elle permet également de choisir la source des données : extraction depuis le portail Smollan ou chargement de fichiers Excel présents localement sur la machine.




Figure 4.3 Interface de sélection des fichiers du pipeline ETL

La figure 4.3 montre les principales options disponibles au lancement. Le mode portail permet d'extraire les fichiers sélectionnés avant leur chargement dans MySQL, tandis que le mode local permet de sélectionner directement les fichiers Excel depuis la machine. L'interface propose également l'exécution des règles de validation après le chargement du *Data Dump*, ce qui permet d'intégrer les contrôles métier dans le flux de traitement.

II.1.3 Configuration de l'environnement

La configuration du pipeline repose sur un fichier `.env`. Ce fichier permet de centraliser les paramètres nécessaires à la connexion à la base MySQL, à l'export depuis le portail Smollan et à l'organisation des répertoires utilisés par le pipeline. Les informations sensibles, notamment les identifiants et les mots de passe, ne sont pas affichées dans le rapport et doivent rester anonymisées.

```
# Data Engineering environment template.

# MySQL database used by the Python ETL.
MYSQL_HOST=127.0.0.1
MYSQL_PORT=3306
MYSQL_DATABASE=unilever_db
MYSQL_USER=root
MYSQL_PASSWORD=*****

# Smollan portal automation. Fill these only in your local .env file.
PORTAL_BASE_URL=https://smartmanagement.smollan.com/#/login
PORTAL_USERNAME=*****
PORTAL_PASSWORD=*****
PORTAL_ENTITY=Morocco Unilever
DATA_DUMP_REPORT_NAME=Data Dump
COVERAGE_REPORT_NAME=Coverage Data
COVERAGE_LOOKBACK_DAYS=4

# Local file locations for generated/downloaded files.
DOWNLOAD_DIR=./data-engineering/downloads
BACKUP_DIR=./data-engineering/backups
LOG_DIR=./logs

# Playwright runtime options.
PORTAL_HEADLESS=false
PORTAL_SLOW_MO_MS=250
PORTAL_TIMEOUT_MS=30000
PORTAL_EXPORT_TIMEOUT_MS=300000
```


Figure 4.4 Exemple anonymisé de configuration de l'environnement

La figure 4.4 montre les principaux paramètres utilisés par le pipeline. Les variables liées à MySQL permettent d'identifier la base *unilever_db*. Les variables liées au portail définissent l'URL, l'entité concernée, les rapports à extraire et les options d'exécution de Playwright. Enfin, les chemins de téléchargement, de sauvegarde et de logs permettent d'organiser les fichiers générés ou utilisés pendant le traitement.

II.1.4 Orchestration et suivi d'exécution avec Prefect

L'exécution du pipeline est orchestrée à l'aide de Prefect afin de mieux structurer les différentes étapes du traitement et de suivre leur état d'exécution. Dans le cadre du projet, Prefect ne sert pas uniquement à lancer le pipeline, mais à organiser son déroulement autour de phases fonctionnelles clairement identifiables : les contrôles préalables, l'acquisition des fichiers, le traitement du *Data Dump*, l'exécution des règles de validation, le traitement du *Coverage* et la synthèse finale de l'exécution.

Avant le lancement d'un traitement supervisé, le serveur Prefect doit être démarré localement. Cette étape permet d'activer l'API locale utilisée par le pipeline et de rendre disponible l'interface de suivi des exécutions. Lorsque le serveur n'est pas actif, le pipeline ne peut pas communiquer avec l'API de Prefect, ce qui empêche le suivi correct du run.



```
o (.venv) PS C:\Users\hamza\CHARMAQE\MySpace\merch-performance-app\data-engineering> prefect server start

  _____
 /_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \
/_ _ _ _ _ \

Configure Prefect to communicate with the server with:

    prefect config set PREFECT_API_URL=http://127.0.0.1:4200/api

View the API reference documentation at http://127.0.0.1:4200/docs

Check out the dashboard at http://127.0.0.1:4200
```

Figure 4.5 Démarrage du serveur Prefect

La figure 4.5 présente la commande utilisée pour démarrer le serveur Prefect. Une fois le serveur lancé, Prefect met à disposition une API locale ainsi qu'un tableau de bord permettant de suivre les exécutions du pipeline, de consulter les runs et d'identifier l'état des différentes étapes.

La structure retenue repose sur un flux principal intitulé *Merch Performance Daily ETL Orchestration*. Ce flux principal est organisé en sous-flux fonctionnels afin de séparer les responsabilités du pipeline sans afficher toutes les opérations internes comme des tâches indépendantes. Les opérations de bas niveau, telles que les transformations de *DataFrames*, les insertions SQL, les boucles d'idempotence ou les requêtes propres aux règles de validation, restent encapsulées dans des fonctions Python internes.

Name	Last run	Next run	Deployments	Activity
Coverage processing Created 2020/06/04 12:48:34 PM	chocolate-flamingo		None	
Data Dump processing Created 2020/06/04 12:44:38 PM	modern-tarantula		None	
Input acquisition and traceability Created 2020/06/04 12:42:58 PM	weightless-myna		None	
Merch Performance Daily ETL Orchestration Created 2020/06/04 01:31:22 PM	ancient-rat		None	
Merch Performance Monitored Pipeline Created 2020/06/04 12:42:48 PM	fictional-wrasse		None	
Pre-run checks Created 2020/06/04 12:42:48 PM	resilient-cat		None	
Validation processing Created 2020/06/04 12:48:07 PM	influential-anteater		None	

Figure 4.6 Vue des runs supervisés dans Prefect

La figure 4.6 montre les principaux runs enregistrés dans Prefect. On y distingue le flux principal ainsi que les sous-flux associés aux grandes phases du traitement : contrôles préalables, acquisition et traçabilité des fichiers, traitement du *Data Dump*, traitement des validations et traitement du *Coverage*. Cette organisation rend le suivi plus lisible et permet d'identifier rapidement la phase concernée en cas d'erreur.




Figure 4.7 Vue globale de l'orchestration du pipeline dans Prefect

La figure 4.7 illustre la relation entre le flux principal et les sous-flux fonctionnels. Le pipeline commence par les vérifications préalables et l'acquisition des fichiers, puis enchaîne avec le traitement du *Data Dump*, l'exécution des règles de validation, le traitement du *Coverage* et la synthèse finale. Cette structuration permet de conserver un équilibre entre lisibilité dans l'interface Prefect et niveau de détail nécessaire au suivi technique du pipeline.

Ainsi, Prefect apporte une meilleure traçabilité par rapport à une exécution classique d'un script unique. Il permet de suivre les temps d'exécution, de distinguer les étapes fonctionnelles du pipeline et de faciliter l'analyse des erreurs éventuelles.

II.2 Traitement du fichier Data Dump

Le fichier *Data Dump* constitue la source principale des réponses terrain. Il contient les informations issues des visites réalisées dans l'application Smart 3, notamment les données liées aux merchandisers, aux magasins, aux produits, aux tâches, aux questions et aux réponses saisies. Son traitement consiste à transformer ces lignes brutes en tables structurées dans MySQL.

Afin d'illustrer cette transformation, deux exemples représentatifs sont retenus : les réponses OSA et les données SOS. Ces deux cas montrent que le pipeline n'applique pas une transformation unique à toutes les tâches, mais adapte la structure SQL selon la logique métier de chaque type de donnée.




Figure 4.8 Transformation du Data Dump vers les tables SQL : exemples OSA et SOS

II.2.1 Principe général de transformation

Le traitement commence par la lecture des lignes du fichier *Data Dump*. Chaque ligne correspond à une réponse terrain associée à une tâche, un titre, une question et une réponse. Le pipeline identifie ensuite la tâche métier concernée, rattache la ligne à la visite correspondante et, lorsque cela est possible, l'associe également au produit concerné.

Cette étape permet de passer d'une logique de fichier Excel, orientée lignes de réponses, vers une logique de tables SQL structurées. Les champs de liaison utilisés pour rattacher les réponses aux visites reposent principalement sur la date, le code merchandiser et le code magasin. Le code produit permet ensuite d'enrichir certaines tâches, notamment les tâches liées à la disponibilité produit.

II.2.2 Étude de cas OSA : transformation en colonnes dynamiques

Le premier cas concerne les réponses OSA. Dans le fichier *Data Dump*, ces réponses sont stockées sous forme de lignes question/réponse associées à une visite et à un produit. Le traitement appliqué vise à transformer ces lignes brutes en une structure SQL plus adaptée à l'analyse de la disponibilité produit.

Étude de cas OSA — Pivot dynamique	
Entrée Data Dump	Ligne question/réponse liée à une visite, à un produit et à une réponse de disponibilité du SKU, généralement sous la forme <i>Oui</i> ou <i>Non</i> .
Règle appliquée	Les lignes dont le titre contient <i>OSA</i> , <i>COC</i> , <i>MH</i> ou <i>PACK</i> sont orientées vers la table <i>task_osa_pack_coc_mh</i> .
Transformation	Les réponses sont regroupées par <i>visit_id</i> et <i>product_id</i> . Chaque question devient une colonne SQL dynamique, tandis que la réponse devient la valeur stockée dans cette colonne.
Sortie SQL	La table cible contient une ligne par visite et par produit, avec des colonnes fixes comme <i>visit_id</i> , <i>product_id</i> , <i>title</i> et <i>response_date</i> , ainsi que des colonnes dynamiques générées à partir des questions.
Utilité	Cette structure facilite l'analyse de la disponibilité des produits et prépare les données pour les indicateurs OSA et les règles de contrôle métier.

Tableau 4.1 Étude de cas OSA : transformation en colonnes dynamiques

Cette logique correspond à une transformation de type *pivot*. Elle permet de passer de plusieurs lignes question/réponse vers une ligne structurée par produit visité.

II.2.3 Étude de cas SOS : transformation en structure verticale

Le second cas concerne les données SOS. Contrairement à l'OSA, les réponses SOS ne sont pas transformées en colonnes dynamiques. Elles sont conservées sous forme verticale afin de représenter les mesures de part de linéaire, les valeurs relevées et le total associé.

Étude de cas SOS — Structure verticale	
Entrée Data Dump	Ligne liée à une mesure de part de linéaire, contenant une question, une valeur relevée et un contexte de visite.
Règle appliquée	Les lignes dont le titre contient <i>SOS</i> sont orientées vers la table <i>task_sos</i> . Le traitement ne transforme pas les questions en colonnes dynamiques.
Transformation	La question est conservée dans <i>qst</i> , la réponse dans <i>qst_value</i> , et le total associé dans <i>total</i> . Chaque ligne SOS reste donc un item d'analyse.
Sortie SQL	La table cible contient une ligne par item SOS, avec les champs <i>visit_id</i> , <i>task</i> , <i>response_date</i> , <i>qst</i> , <i>qst_value</i> et <i>total</i> .
Utilité	Cette structure facilite les agrégations et les comparaisons nécessaires à l'analyse de la part de linéaire et de la visibilité en rayon.

Tableau 4.2 Étude de cas SOS : transformation en structure verticale

Cette logique verticale est plus adaptée au SOS, car elle conserve les mesures sous une forme directement exploitable pour les analyses quantitatives.

II.2.4 Sorties générées et fiabilisation du rechargement

À partir du fichier *Data Dump*, le pipeline alimente plusieurs familles de tables. Les tables *employees*, *stores*, *products* et *visits* structurent les principales entités métier. Les tables *task_** conservent les réponses selon leur logique opérationnelle, tandis que *survey_responses* fournit une vue normalisée des réponses terrain.

Afin de fiabiliser les relances du pipeline, les données détaillées associées aux visites re-traitées sont nettoyées avant leur réinsertion. Cette opération concerne les tables *task_** et *survey_responses*. Elle permet d'éviter l'accumulation de doublons et de garantir que les données détaillées correspondent au dernier fichier traité.

II.3 Intégration du Coverage et rapprochement avec le Data Dump

Le fichier *Coverage* constitue la deuxième source principale du pipeline. Contrairement au fichier *Data Dump*, qui contient les réponses détaillées issues des tâches terrain, le *Coverage* apporte une vision opérationnelle de l'exécution des visites. Il permet notamment de suivre les visites planifiées, réalisées, rejetées, déviées ou non effectuées.

Dans la solution, le *Coverage* est chargé dans la table *fact_coverage*. Cette table conserve le grain opérationnel du fichier source, basé principalement sur la date de visite, le merchandiser et le magasin. Cette séparation est volontaire, car certaines lignes du *Coverage*, comme les visites non effectuées ou rejetées, peuvent exister sans disposer de réponses détaillées dans le

Data Dump.

II.3.1 Rôle de la table de couverture opérationnelle

La table *fact_coverage* joue le rôle d'une table de faits opérationnelle. Elle centralise les informations nécessaires au suivi de l'exécution terrain : statut de visite, couverture, rejet, déviation, non-visite, distances GPS, temps d'exécution et motifs éventuels.

Son objectif n'est pas de remplacer les tables issues du *Data Dump*, mais de compléter leur lecture. Le *Data Dump* permet d'analyser le contenu détaillé des visites exécutées, tandis que le *Coverage* permet d'évaluer l'état global de l'exécution, y compris les cas où aucune réponse terrain détaillée n'est disponible.

II.3.2 Rapprochement optionnel avec les visites détaillées

Afin de relier le suivi opérationnel issu du *Coverage* avec les visites détaillées issues du *Data Dump*, une vue SQL de rapprochement a été ajoutée : *vw_fact_coverage_visit_match*. Cette vue ne remplace pas les tables existantes et ne modifie pas leur structure. Elle agit comme une couche logique de lecture permettant de comparer les lignes de *fact_coverage* avec les visites présentes dans la table *visits*.

L'intérêt de cette approche est de conserver toutes les lignes du *Coverage*, y compris les visites non effectuées, rejetées ou planifiées sans données détaillées. Le rapprochement est donc volontairement optionnel : lorsqu'une visite détaillée existe dans le *Data Dump*, la vue expose son *visit_id*. Dans le cas contraire, la ligne *Coverage* reste visible avec un statut indiquant l'absence de visite détaillée.




Figure 4.9 Implémentation de la vue SQL de rapprochement dans la base unilever_db

La figure 4.9 montre que le rapprochement a été implémenté sous forme d'une vue SQL distincte, et non comme une nouvelle table physique. Cette séparation permet de garder *fact_coverage* comme table de faits opérationnelle, tout en ajoutant une lecture croisée avec les visites détaillées lorsque celles-ci existent.

Logique de la vue de rapprochement

Source principale : *fact_coverage*, qui conserve les statuts opérationnels des visites : visité, non visité, rejeté ou en déviation.

Source rapprochée : *visits*, alimentée à partir du *Data Dump* et représentant les visites disposant de données détaillées.

Clé utilisée : *visit_date* + *employee_code* + *store_code*.

Résultat ajouté par la vue : le champ *visit_id*, lorsqu'une correspondance est trouvée, et le champ *match_status* pour qualifier le rapprochement.

Statut *MATCHED* : la ligne Coverage possède une visite détaillée correspondante dans le *Data Dump*.

Statut *NO_DATA_DUMP_VISIT* : la ligne existe dans le *Coverage*, mais aucune visite détaillée correspondante n'existe dans le *Data Dump*.

Cette approche renforce l'exploitation du fichier *Coverage*. Celui-ci n'est pas seulement chargé dans une table, mais intégré comme une source de suivi opérationnel pouvant être comparée aux visites détaillées issues du *Data Dump*. La vue permet ainsi d'identifier les visites disposant de réponses terrain, tout en conservant les situations présentes uniquement dans le

suivi opérationnel.

II.3.3 Apport dans la solution

Cette modélisation renforce la cohérence globale de la solution. Elle évite de forcer une relation physique entre *fact_coverage* et *visits*, ce qui aurait pu poser problème pour les visites non effectuées ou rejetées. À la place, la vue SQL propose une lecture contrôlée et réversible, sans imposer de modification directe aux tables existantes ni aux services applicatifs déjà mis en place.

Elle constitue également une base utile pour les analyses futures, car elle distingue clairement les visites ayant des réponses détaillées de celles qui existent uniquement dans le suivi de couverture. Cette distinction peut ensuite être exploitée dans les tableaux de bord, les contrôles opérationnels ou les interfaces de suivi.

II.4 Modélisation et chargement dans MySQL

Après les étapes de préparation et de transformation, les données sont chargées dans une base MySQL nommée *unilever_db*. Cette base constitue le référentiel central de la solution. Elle permet de conserver les données issues des fichiers *Data Dump* et *Coverage*, de structurer les informations métier et de les rendre accessibles aux règles de validation, aux tableaux de bord et aux services applicatifs.

Le modèle retenu ne cherche pas à reproduire directement la structure des fichiers Excel. Il organise les données selon leur rôle dans la solution : les entités de référence, les visites, les réponses détaillées, les données de couverture, les résultats de validation et les journaux d'exécution.




Figure 4.10 Organisation logique des données dans MySQL

La figure 4.10 présente une vue simplifiée de l'organisation des données dans MySQL. Les

fichiers *Data Dump* et *Coverage* alimentent des tables ayant des rôles complémentaires. Le *Data Dump* permet de construire les tables de référence, les visites, les tables de tâches et la table normalisée *survey_responses*. Le *Coverage* alimente la table *fact_coverage*, utilisée pour le suivi opérationnel des visites.

Cette organisation permet de séparer les données stables, les données opérationnelles et les données analytiques. Elle facilite également l'exploitation des données par les règles de validation, les tableaux de bord et les APIs applicatives.

II.4.1 Stratégie de chargement

Le chargement des données s'effectue de manière contrôlée afin d'éviter les doublons et de garantir la cohérence des informations insérées. Les tables de référence sont alimentées à partir des codes métier, comme le code employé, le code magasin ou le code produit. Lorsque ces éléments existent déjà dans la base, les informations peuvent être mises à jour sans créer de doublons.

Les visites sont chargées à partir d'une clé naturelle composée de la date de visite, du merchandiser et du magasin. Cette clé permet d'identifier une visite de manière cohérente et de relier ensuite les réponses terrain aux visites correspondantes.

Pour les données détaillées issues du *Data Dump*, le pipeline applique une logique de rechargement contrôlé. Avant d'insérer les nouvelles réponses associées aux visites retraitées, les anciennes lignes correspondantes sont supprimées des tables de tâches et de la table *survey_responses*. Cette étape permet de reconstruire proprement les données détaillées à partir du dernier fichier traité.

II.4.2 Traçabilité des traitements

La traçabilité constitue un élément important du chargement. Le pipeline conserve des informations sur les exécutions réalisées, notamment à travers la table *etl_run_log*. Cette table permet de suivre les traitements effectués, les fichiers concernés, les dates d'exécution et l'état global du chargement.

Cette logique de suivi facilite l'analyse en cas d'erreur ou d'incohérence. Elle permet également de mieux comprendre l'historique des traitements appliqués aux données et de vérifier que les différentes étapes du pipeline ont été exécutées correctement.

Ainsi, le chargement dans MySQL représente une étape centrale de la solution. Il transforme les fichiers Excel traités en un modèle relationnel exploitable, capable d'alimenter les validations métier, les tableaux de bord et les interfaces de consultation.

III. Structuration de la base de données

La base MySQL *unilever_db* est structurée selon le rôle des données dans la solution. L'objectif n'est pas de reproduire directement les fichiers Excel, mais d'organiser les informa-

tions autour de plusieurs familles de tables : tables de référence, tables opérationnelles, tables détaillées d'exécution, vue de rapprochement, tables de validation et tables de traçabilité.

Modèle relationnel simplifié de la base unilever_db

Vue simplifiée des principales tables utilisées pour le pipeline, la validation et l'exploitation des données




Figure 4.11 Modèle relationnel simplifié de la base unilever_db

La figure 4.11 présente un modèle relationnel simplifié de la base. Elle ne reprend pas toutes les colonnes techniques, mais met en évidence les principales relations entre les visites, les magasins, les produits, les réponses terrain, la couverture opérationnelle et les résultats de validation.

Les tables *employees*, *stores* et *products* jouent le rôle de tables de référence. Elles décrivent les entités métier principales et évitent de répéter les mêmes informations dans les tables d'exécution. Les tables *visits* et *fact_coverage* représentent les données opérationnelles :

la première porte les visites détaillées issues du *Data Dump*, tandis que la seconde conserve le suivi opérationnel issu du *Coverage*.

Les tables *task_** stockent les réponses détaillées selon la nature des tâches terrain. Certaines tâches, comme l'OSA, utilisent une logique de colonnes dynamiques, tandis que d'autres, comme le SOS, conservent une structure verticale. La table *survey_responses* complète ces tables spécialisées en fournissant une vue normalisée et transversale des réponses terrain.

La vue *vw_fact_coverage_visit_match* permet de rapprocher le *Coverage* et les visites détaillées sans imposer de relation physique obligatoire. Enfin, les tables *validation_rules*, *validation_run_log*, *validation_results* et *etl_run_log* assurent le suivi des règles métier, des résultats de validation et des exécutions du pipeline.

IV. Mise en place du moteur de validation

Après la structuration des données dans MySQL, une couche de validation a été mise en place afin de détecter certaines situations nécessitant une vérification opérationnelle. Ce moteur est implémenté en Python et s'appuie sur les données déjà chargées dans la base, notamment les visites, les magasins, les merchandisers et les réponses terrain.

L'objectif de cette couche n'est pas de remplacer le contrôle humain, mais d'aider à identifier des situations inhabituelles. Les règles appliquées permettent de repérer des cas pouvant nécessiter une revue, comme des réponses OSA incohérentes avec le comportement global d'une bannière ou des coordonnées GPS inhabituelles sur des visites répétées.

Synthèse des règles implémentées

Règle OSA – formats MT : détection d'une réponse *Non* inhabituelle lorsque le comportement hebdomadaire de la même bannière et du même produit indique une disponibilité majoritairement positive. La règle s'appuie principalement sur *survey_responses*.

Règle GPS – formats GT : détection d'une visite dont la position GPS s'éloigne fortement de la position médiane observée pour le même merchandiser et le même magasin durant le mois. La règle s'appuie principalement sur *visits*.

IV.1 Principe général du moteur de validation

Le moteur de validation est organisé autour d'un registre de règles Python. Les règles disponibles sont déclarées dans ce registre, puis synchronisées avec la table *validation_rules*. Cette table permet de conserver les règles connues par le système et d'indiquer si elles sont actives ou non à l'aide du champ *is_active*.

Lorsqu'une exécution de validation démarre, une ligne est créée dans *validation_run_log*. Le moteur charge ensuite les règles actives, exécute les contrôles correspondants et insère les situations détectées dans *validation_results*. À la fin du traitement, le journal d'exécution est mis à jour avec le statut final, le nombre de règles exécutées et le nombre de situations détectées.

Dans l'orchestration actuelle, la validation est exécutée après le traitement du fichier *Data Dump*. Elle s'appuie donc principalement sur les tables alimentées par ce fichier, notamment *visits* et *survey_responses*. L'exécution peut aussi être limitée aux visites affectées par le chargement en cours, afin d'éviter de retraiter inutilement l'ensemble de l'historique.

IV.2 Règle de validation OSA pour les formats MT

La première règle concerne les réponses OSA pour les formats MT. Elle s'applique uniquement aux magasins de type *HYPERMARKET*, *SUPERMARKET LOWER* et *SUPERMARKET UPPER*. Son objectif est de repérer des réponses de disponibilité produit qui paraissent inhabituelles par rapport au comportement observé sur une même bannière.

La règle analyse les réponses *Oui* et *Non* dans *survey_responses*, puis les rapproche avec les visites et les magasins afin de prendre en compte le format du point de vente et la bannière. Une situation est signalée lorsqu'une réponse individuelle indique *Non*, alors que le comportement hebdomadaire de la même bannière, du même produit et de la même question montre un taux de disponibilité élevé.

Dans l'implémentation actuelle, une situation est générée lorsque le taux de disponibilité hebdomadaire est supérieur ou égal à 90%.

IV.3 Règle de validation GPS pour les formats GT

La seconde règle concerne la cohérence GPS des visites répétées dans les formats GT. Elle s'applique uniquement aux magasins de type *GROCERY* et *CASH AND CARRY*. Son objectif est d'identifier des coordonnées GPS inhabituelles pour des visites répétées au même point de vente.

La règle analyse les coordonnées enregistrées dans *visits*. Les visites sont regroupées par merchandiser, magasin, année et mois. Pour chaque groupe disposant d'un nombre suffisant de visites, le moteur calcule une position de référence à partir des coordonnées médianes, puis compare chaque visite à cette position.

Une situation est signalée lorsque la distance entre la position GPS d'une visite et la position médiane du groupe dépasse un seuil défini. Dans l'implémentation actuelle, une anomalie est créée lorsque cette distance dépasse 1000 mètres. La sévérité devient plus élevée lorsque la distance atteint un seuil plus important.

IV.4 Stockage des résultats de validation

Les résultats produits par les règles sont stockés dans la table *validation_results*. Cette table conserve les informations nécessaires à l'analyse des situations détectées : règle appliquée, visite concernée, magasin, merchandiser, produit lorsque celui-ci est disponible, valeur observée, valeur attendue, métrique calculée, message de validation et niveau de sévérité.

La table contient également des champs de revue, tels que le statut de traitement, le commen-

taire, l'utilisateur ayant réalisé la revue et la date de revue. Ces champs permettent d'exploiter les situations détectées dans un portail back-office, où elles peuvent être consultées, analysées et suivies.

La table *validation_run_log* assure la traçabilité des exécutions du moteur. Elle permet de savoir quand une validation a été lancée, si elle s'est terminée correctement, combien de règles ont été exécutées et combien de situations ont été détectées.

Dans l'état actuel de la solution, le moteur de validation reste limité à deux règles principales. Les seuils et les formats concernés sont définis dans le code Python. Cette approche reste adaptée au périmètre actuel du projet, tout en laissant la possibilité d'évoluer vers un moteur plus configurable.

V. Développement de la couche Business Intelligence

La couche Business Intelligence constitue la partie analytique de la solution. Elle permet de transformer les données centralisées dans MySQL en indicateurs de suivi opérationnel exploitables par les équipes métier. Son rôle est de fournir une lecture synthétique de l'exécution terrain, en complément des interfaces applicatives et des règles de validation.

Dans le cadre du projet, Power BI a été utilisé comme outil de restitution afin de construire une première version analytique autour de la couverture, de la performance des merchandisers, des visites problématiques et de certains indicateurs liés à l'exécution terrain. Cette couche ne doit pas être considérée comme une plateforme BI totalement industrialisée, mais comme un modèle analytique préparé à partir de la base *unilever_db*.

V.1 Objectif de la couche BI

L'objectif de la couche BI est de rendre les données opérationnelles plus lisibles pour le suivi métier. Les fichiers *Data Dump* et *Coverage* contiennent une grande quantité d'informations, mais leur exploitation directe reste limitée lorsqu'il s'agit de suivre plusieurs indicateurs, de filtrer par période, superviseur ou merchandiser, ou de comparer les performances d'exécution.

Power BI permet donc de regrouper les indicateurs clés dans des vues de pilotage. Ces vues facilitent le suivi du taux de couverture, de la complétion des tâches, des déviations, des visites non effectuées, des rejets, des distances GPS et de la performance par merchandiser. Elles permettent également de passer d'une lecture fichier par fichier à une lecture plus synthétique et interactive de l'exécution terrain.

V.2 Connexion directe à la base MySQL

La préparation de la couche BI commence par une connexion directe entre Power BI et la base MySQL *unilever_db*. Ce choix permet d'exploiter les données déjà centralisées par le pipeline Data Engineering, au lieu de repartir des fichiers Excel bruts. La couche BI s'appuie donc sur le même référentiel de données que le reste de la solution.




Figure 4.12 Connexion de Power BI à la base MySQL unilever_db

La figure 4.12 illustre les premières étapes de connexion à la base MySQL. Power BI permet d'abord de sélectionner le connecteur MySQL, puis de renseigner les informations nécessaires à l'accès à la base locale, notamment le serveur, le port, le nom de la base et les identifiants de connexion. Cette connexion directe permet d'utiliser les données structurées dans MySQL comme source principale du modèle BI.

V.3 Sélection des tables utiles

Après la connexion à MySQL, les tables nécessaires sont sélectionnées depuis le navigateur Power BI. Toutes les tables de la base ne sont pas utilisées dans le modèle BI. La sélection se fait selon les besoins d'analyse : suivi de couverture, performance merchandiser, analyse des tâches terrain, filtres par magasin, période ou superviseur.

Les tables sélectionnées concernent principalement la table *fact_coverage*, les visites, les référentiels métier et les tables de tâches. Les tables de validation, telles que *validation_results*, *validation_rules* et *validation_run_log*, sont plutôt destinées au portail back-office de suivi des situations détectées. Elles ne constituent donc pas la source principale de la couche BI opérationnelle.

V.4 Préparation du modèle Power BI

Une fois les tables importées, le modèle Power BI est structuré à travers les relations nécessaires entre les tables. Cette étape permet d'assurer la cohérence des filtres entre les dates, les merchandisers, les magasins et les données opérationnelles. Elle constitue une phase importante, car les indicateurs ne dépendent pas uniquement des tables importées, mais aussi de la manière dont elles sont reliées dans le modèle.

La table *fact_coverage* constitue la source principale des indicateurs opérationnels, car elle contient les informations liées aux visites planifiées, réalisées, non visitées, rejetées ou en déviation. Elle est complétée par des tables de référence comme les employés, les magasins, les

Logique du score de productivité

Le score de productivité combine trois facteurs positifs : le taux de couverture, la complétion des tâches et la conformité GPS. Il applique également une pénalisation liée au taux de déviation et au taux de rejet. Cet indicateur a été construit dans le cadre du projet afin de faciliter la comparaison analytique entre merchandisers, sans remplacer l'analyse détaillée des indicateurs qui le composent.

V.6 Vues de restitution préparées

Deux vues principales ont été préparées dans Power BI. La première correspond au *National Retail Execution Dashboard*. Elle permet de suivre les indicateurs globaux de l'exécution terrain, notamment la couverture, les tâches réalisées, les visites planifiées, les visites non effectuées, les rejets, les déviations et les visites problématiques.

La seconde vue correspond au *Merchandise Performance Intelligence*. Elle est orientée vers l'analyse individuelle des merchandisers. Elle permet de suivre la couverture, la complétion des tâches, la durée de travail, la durée moyenne de visite, les indicateurs GPS, les visites non effectuées et les situations problématiques associées à un merchandiser donné.

Dans ce chapitre, la couche BI est présentée sous l'angle de sa préparation technique : connexion à MySQL, sélection des tables utiles, construction du modèle, création des mesures et préparation des vues de restitution. Les captures et l'interprétation des tableaux de bord seront présentées dans le chapitre consacré à la réalisation et aux résultats.

VI. Développement de la couche backend

VI.1 Architecture Spring Boot et Java

VI.2 APIs REST destinées à l'application mobile

VI.3 APIs REST destinées au back-office

VII. Développement des interfaces applicatives

VII.1 Interface mobile Expo / React Native

VII.2 Portail back-office React

VII.3 Limites actuelles de l'authentification

VIII. Conclusion

CHAPITRE 5 : RÉALISATION, TESTS ET RÉSULTATS

I. Introduction

II. Résultats du pipeline Data Engineering

II.1 Exécution du pipeline ETL

II.2 Données chargées dans MySQL

II.3 Journaux d'exécution

III. Résultats du moteur de validation

III.1 Résultats de la règle OSA pour les formats MT

III.2 Résultats de la règle GPS pour les formats GT

III.3 Exemples de situations détectées

IV. Tests des services backend

IV.1 Tests des APIs mobiles

IV.2 Tests des APIs back-office

V. Résultats des tableaux de bord Power BI

V.1 Dashboard exécutif

V.2 Dashboard Merchandiser Performance Intelligence

V.3 Analyse GT / MT

V.4 Apport pour le management et le field team

VI. Résultats des interfaces applicatives

VI.1 Interface mobile de consultation

VI.2 Portail back-office de validation

VII. Limites et état actuel de la solution

VIII. Conclusion

CONCLUSION GENERALE

Synthese du travail realise

Apports du projet

Limites et perspectives

Conclusion finale

BIBLIOGRAPHIE

CHAPITRE A : ANNEXES

I. Schemas techniques

II. Captures d'ecran

III. Exemples techniques